

分类号

密级

太原理工大学

硕士学位论文

题目 改进区域模型的水平集图像分割算法研究

英文并列题目 Level Set Method of Image Segmentation Based on Improved Region

研究生姓名: 赵 怡

学 号: 2015510335

专 业: 计算机科学与技术

研究 方 向: 图像处理

导 师 姓 名: 邓红霞

职 称: 副教授

论文提交日期 2018/06

学位授予单位: 太原理工大学
地 址: 山西·太原

太 原 理 工 大 学

声 明

本人郑重声明：所呈交的学位论文，是本人在指导教师的指导下，独立进行研究所取得的成果。除文中已经注明引用的内容外，本论文不包含其他个人或集体已经发表或撰写过的研究成果。对本文的研究做出重要贡献的个人和集体，均已在文中以明确方式标明。本声明的法律责任由本人承担。

论文作者签名： 赵怡 日期： 2018.6.7

关于学位论文使用权的说明

本人完全了解太原理工大学有关保管、使用学位论文的规定，其中包括：①学校有权保管、并向有关部门送交学位论文的原件与复印件；②学校可以采用影印、缩印或其它复制手段复制并保存学位论文；③学校可允许学位论文被查阅或借阅；④学校可以学术交流为目的，复制赠送和交换学位论文；⑤学校可以公布学位论文的全部或部分内容（保密学位论文在解密后遵守此规定）。

签 名： 赵怡 日期： 2018.6.7

导师签名： 邓红霞 日期： 2018.6.7

改进区域模型的水平集图像分割方法研究

摘 要

图像分割是计算机视觉领域至关重要的步骤，在科研领域内受到国内外学者的广泛研究并形成了多种多样的算法。其中，基于水平集的图像分割方法凭借其独有的算法优势，如自由拓扑变换，强大的数学基础，多信息共融性与较好的扩展性等，成为近年来图像分割领域的热点方向并迅速发展。本文研究了基于区域的水平集图像分割方法，并针对现有模型存在的不足之处进行了改进创新，最后结合多种人工合成图像和工程实践中的真实图像来验证模型的可行性。本文所作的具体创新工作如下：

(1) 提出了一种能够有效解决局部极小值问题的模型 VLIF，有效解决了现有局部模型在分割灰度不均匀图像时容易陷入局部极小值造成分割失败的问题。该模型结合最大类间方差思想，在 LIF 模型的基础上增加类间方差能量项，通过最大化演化曲线上所有点的邻域内目标和背景的差异来剔除使演化曲线陷入局部极小值的伪边界点，驱使演化曲线停最终留在正确的目标边界。为了证明提出模型的有效性，本文进行了一系列对比实验，结果表明改进的模型可以有效地解决局部模型因陷入局部极小值而导致的误分割问题，提高对灰度不均匀以及复杂图像的分割准确度。

(2) 提出了一种权重自适应的融合图像全局信息和局部信息的活动轮廓模型。利用图像局部熵建立了精确可靠的衡量图像灰度信息的指标，通过实时获取图像分割过程中的灰度分布情况自适应的指导模型中不同功能

能量项配比，实现全自动化分割。相比传统基于反复试验的固定参数线性调整模式，本文选择了一种更加合理的方式实现了全局项与局部项的动态非线性调整，实现了对多种类型图像的快速准确分割。最后通过一系列实验表明本文模型对于不同类型的灰度不均匀和噪声图像，能够完成快速准确的分割，且稳定性较高，对初始轮廓的位置也不敏感。

关键字：图像分割，水平集方法，最大类间方差，图像熵，权重自适应

Level Set Method of Image Segmentation Based on Improved Region Models

Abstract

Image segmentation is a crucial step in the field of computer vision. In the field of scientific research, it has been widely studied by scholars at home and abroad and has formed a variety of algorithms. Among them, the image segmentation based on level set method has become the hotspot and develop rapidly in recent years due to its unique algorithm advantages such as free topology transformation, strong mathematics foundation, multi-information communicability, and good expandability. In this paper, we studied the region-based level set method, and improved the existing deficiencies in the existing models. Finally, we combined many kinds of artificial synthetic images and real images in engineering practice to verify the feasibility of the model. The innovation works made in this paper are as follows:

Aiming at the phenomenon that the existing local models are easy to fall into local minimum and causes segmentation failure when segmenting images with intensity inhomogeneity, an improved model VLIF which can effectively solve this problem is proposed. This model incorporates the idea of maximum

variance between classes and adds a class-to-class variance energy term based on the LIF model. By maximizing the difference between the target and the background in the neighborhood of all points on the evolution curve, the pseudo edge points which lead the evolution curve into a local minimum are eliminated. Then the evolution curve been driven to stay at the correct target boundary. In order to prove the validity of the proposed model, a series of experiments were conducted in this paper. The results show that the improved model can effectively solve the problem caused by the local minimum in local models and improves the accuracy of segmenting result in intensity inhomogeneity and complex images.

A weight-self adjustment active contour model combined with the image global information and local information is proposed. The local entropy of the image is used to establish an accurate and reliable index for measuring image intensity information. In order to achieve fully automated segmentation, we can obtain the intensity distribution in the process of image segmentation to guide the matching of different functional energy items in the model adaptively in the real time. Compared to the traditional fixed-parameter linear adjustment model based on trial and error, this paper selects a more quantified and reasonable way to achieve the dynamic nonlinear adjustment of global items and local items and realizes fast and accurate segmentation of various types of images. Finally, through a series of experiments, it is shown that the proposed model can achieve

fast and accurate segmentation for different types of intensity inhomogeneous and noisy images with high stability and insensitive to the position of the initial contour.

Keywords: Image segmentation, level set method, maximum variance between classes, image entropy, weight adaptation

目录

第一章 绪论.....	1
1.1 研究背景与意义.....	1
1.2 国内外研究现状.....	3
1.2.1 图像分割方法.....	3
1.2.2 水平集图像分割算法的优势.....	5
1.2.3 水平集图像分割算法.....	6
1.3 研究内容与创新.....	8
1.4 论文结构安排.....	9
第二章 水平集图像分割数学基础.....	11
2.1 曲线演化问题.....	11
2.2 水平集理论.....	13
2.2.1 水平集基础理论.....	13
2.2.2 水平集的数值计算.....	14
2.3 经典的活动轮廓模型.....	15
2.3.1 参数活动轮廓模型.....	16
2.3.2 GAC 模型.....	17
2.3.3 Mumford-Shah 模型.....	18
2.4 本章小结.....	18
第三章 基于最大类间方差的局部分割模型.....	19
3.1 研究背景.....	19
3.2 相关模型.....	20
3.2.1 RSF 模型.....	20
3.2.2 LIF 模型.....	21
3.2.3 最大类间方差思想.....	23
3.3 基于最大类间方差的 VLIF 模型.....	25
3.4 能量泛函求解.....	26
3.5 实验结果与分析.....	29
3.5.1 对灰度不均匀图像的分割.....	29
3.5.2 对医学图像的分割.....	31

3.5.3 对场景复杂的自然图像的分割.....	33
3.5.4 分割精度.....	35
3.6 本章小结.....	38
第四章 引入图像熵的权重自适应活动轮廓模型.....	39
4.1 研究背景.....	39
4.2 相关理论.....	40
4.2.1 图像熵理论.....	40
4.2.2 局部图像熵.....	40
4.2.3 CV 模型.....	41
4.3 基于图像熵的权重自动调节活动轮廓模型.....	41
4.4 能量泛函求解.....	42
4.5 实验结果与分析.....	44
4.5.1 对初始轮廓的敏感度实验.....	45
4.5.2 权重函数自动调节的有效性.....	46
4.5.3 对自然图像的分割.....	47
4.5.4 医学图像分割.....	48
4.5.5 迭代时间与次数.....	51
4.6 本章小结.....	52
第五章 总结与展望.....	53
5.1 工作总结.....	53
5.2 工作展望.....	53
参考文献.....	55
致谢.....	61
攻读学位期间发表的学术论文目录.....	63

第一章 绪论

1.1 研究背景与意义

随着计算机科学技术的迅猛发展与互联网的普及，人类社会每时每刻都在产出海量数据，由此迎来了大数据时代。每个个体在日常的工作生活中都需要产出和获取大量信息，在数字、音频、图像等众多信息表达方式中，图像信息凭借其直观易懂且所表达的信息量大等特点成为追求高效和快捷的当今社会最受欢迎的表达方式。此外，随着电子、计算机科学技术的发展以及图像采集技术的提高和普及，图像处理技术也随之渗透到智能生活以及工程实践的各个领域，如生物特征识别中利用人脸、虹膜和指纹进行快捷高效，安全可靠的身份验证，日常生活中利用二维码进行快捷支付，医学图像分析中对计算机断层扫描成像（CT）和核磁共振成像（MRI）的分析，遥感图像分析，智能安全监控如视频跟踪识别工农业生产自动化，光学字符识别，智能交通管理等。在不同的应用领域中，图像可能会因为采集设备的不同或环境的干扰等问题带来光照不均匀、噪声、图像不清晰等不利于分割的因素，这些不利因素使得图像分割成为一个十分复杂的问题。与此同时，随着人工智能化时代的到来，人类对能够处理和识别复杂图像的人工智能系统也提出了巨大的要求^[1]，图像处理技术也随之迎来了新的挑战。

图像处理技术涉及到多个方面，理论上根据抽象程度，操作对象和数据量等特点将图像工程分为图像处理、图像分析和图像理解三层结构，如图 1-1 所示，无论是图像处理、图像分析、还是图像理解，其工作都建立在图像分割的基础上，所以图像分割是图像处理过程中最重要和关键的一环^[2]。

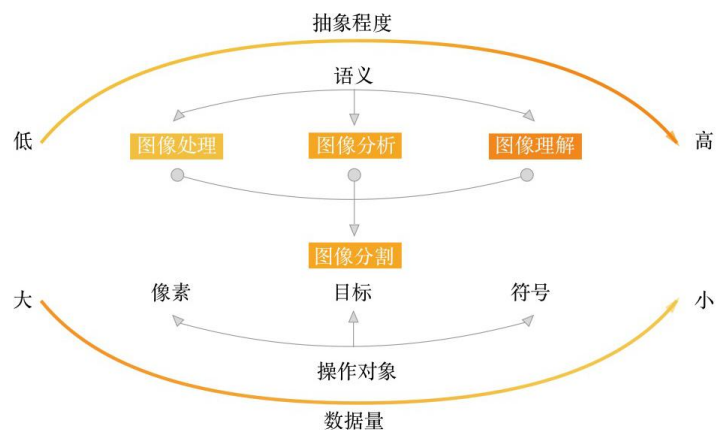


图 1-1 图像工程的三层结构

Fig1-1 Three levels of image engineering.

图像分割的任务是在一幅包含大量信息的图像中，将我们感兴趣的信息或下一步将要研究的主体提取出来，剔除其他不必要的信息，为后续的图像分析与理解等工作降低工作量。其工作原理是根据图像不同区域的特征，如灰度，纹理，色彩等，采用某种相似性度量，将其分割成多个互不交叉的子域，相邻区域由突出的边缘或轮廓分隔，每个区域具有相似的颜色或纹理特征，于是一幅多信息的原始图像经过图像分割处理后展现成为更抽象紧凑的形式，为后续的图像分析与理解工作奠定了基础。在计算机视觉中，图像分割被认为是所有高级视觉任务如对象识别和图像语义理解的关键步骤，是所有基于图像分析的人工智能技术的必要前提。

利用计算机对数字图像进行分割，相较于传统的手动分割方法，可以通过提高计算机硬件和算法的性能来对那些受环境干扰较大，或者户外环境恶劣的图像进行准确的分割，完成人类无法完成的工作或者肉眼无法判断的高精度的分割，提高分割算法的效率和精度，使之后的图像分析工作更加规范化和科学化。

目前，图像分割在智能生活、医学图像处理、工农业自动化、遥感卫星图像处理、生物特征识别、视频图像处理、图像检索、安保监视，以及航空航天、军事、体育、农业，气象预测等方面都得到广泛的应用^[3]。

在智能生活中，图像分割被广泛应用在利用生物特征进行用户身份识别以及快捷支付的过程中，如人脸识别，指纹识别，虹膜识别中对提取到的生物特征进行分割；在基于图像的商品识别和检索中对物品进行分割的先置工作；在基于 VR 和 AR 的应用中对现实场景进行分析。

在医学图像解释中，图像分割被应用于人体器官组织在医学影像中的分离。如 PET(正电子发射断层影像)、MRI(核磁共振成像)、CT 图像以及超声波图像。计算机图像分割相比医学工作者手工分割可以获取肉眼无法达到的精度级别，大大减轻医务人员的工作量，从而更有效地协助医生对病灶进行定位和诊断。

在遥感以及卫星图像分析中，图像分割被应用于对道路，森林，湖泊，海洋，云系等自然地质结构的分割与勘探。

在安防监控领域的视频图像分析中，需要将目标如车辆，行人，以及对进入监控视野的不明外来物如动物等从背景环境中分割出来，为下一步识别工作奠定基础；

在智能交通监测中对车辆以及车牌字符识别中对目标的分离提取，对是否佩戴安全带的驾驶员进行目标分割提取。

在智能移动机器人的场景理解中，图像分割可以帮助视觉引导的移动机器人自主导航并对其视野中的物体做出反应。

由此可见，图像分割技术在智能生活和生产中有着十分广泛的应用，它与有关图像处理的所有领域密切相关并涉及到对多种类型图像的处理，并且在进行提取、测量、分析图像中的研究对象时，都离不开图像分割工作。

1.2 国内外研究现状

1.2.1 图像分割方法

从数学角度对图像分割过程进行描述。令集合 I 表示一幅待分割的图像，那么对图像 I 的分割过程可理解为将 I 划分为 N 个满足以下 5 个条件的非空子集 $I_1, I_2, I_3, \dots, I_N$ ，

- (1) $I = \bigcup_{i=1}^N I_i$ ；
- (2) 对集合内任意 $i, j \in [1, N]$ ，且 $i \neq j$ ，满足 $I_i \cap I_j = \emptyset$ ；
- (3) 对于 $i \in [1, N]$ ，有 $P(I_i) = TRUE$ ；
- (4) 对集合内任意 $i, j \in [1, N]$ 且 $i \neq j$ ，有 $P(I_i \cap I_j) = FALSE$ ；
- (5) 对于 $i \in [1, N]$ ， I_i 为连通的区域。

其中， $P(I_i)$ 表示集合 I_i 中所有元素的逻辑谓词。

接下来对上述五个条件作出简要阐述。条件一指出一幅完整的图像是由分割得到的所有子区域共同构成；条件二指出分割得到的各个子区域是互不相交的，即任意一个像素点不能同时属于两个子区域；条件三指出属于同一子区域的像素点具有某种相同的属性；条件四表示属于不同子区域的像素点应具有不同的属性；条件五表示在同一个子区域内，任意两个像素点是互相连通的，即分割所得到的子区域是一个连通组元^[4]。

图像分割是图像处理和计算机视觉领域一项基础而关键的技术，如何进行高效精确的图像目标提取工作是一项颇具挑战性的科学难题。多年来，国内外研究学者在图像处理领域进行了大量的研究工作并广泛的应用到智能生活和工程实践中，但由于所处理图像种类的千变万化和实际应用领域的不同，目前还没有形成一套具有普遍适用性的图像分割方法。根据图像分割算法的原理和特征，总体上可以分为经典的图像分割算法和多学科融合的新型分割算法。其中，经典的图像分割算法根据研究对象和策略的不同又可分为基于阈值、基于边缘检测和基于区域的分割算法。

(1) 基于阈值的图像分割算法

阈值分割法是一种传统的图像分割方法，其原理是利用灰度直方图来统计整个图像域内各级灰度的分布规律，然后选定一个或多个阈值将图像划分为若干个具有相同灰度特性的子区域^[5]，进而实现对图像的分割。基于阈值的分割方法处理过程：首先选出合适的阈值；然后比较每个像素的灰度值与选定阈值的大小，并根据二者的灰度差将像素点归纳到相应的类别中。由此可见，阈值的选取对图像分割效果起着决定性作用。若阈值选取过大，那么目标区域中的像素点就被错误的划分到背景区域中，从而发生分割不足的情况；若阈值选取过小，则会导致过分割。常见的阈值分割法有：最大类间方差法、最小误差法、最大熵自动阈值法等^[6]。阈值分割法适用于分割目标和背景有明显灰度差异的图像，对于空间结构复杂和各区域灰度值相似的图像，则不再适用。

（2）基于边缘检测的图像分割算法

边缘检测法是一种通过捕捉图像中灰度、颜色、纹理等发生突变的地方寻找边缘的方法。边缘是指图像子区域交界线上像素的集合。一般情况下，目标边缘通常存在于图像特征存在突变的区域，边缘检测首先利用微分算子检测图像中特征发生突变的地方，通常采用一阶导数极大值或二阶导数过零点的信息来构造边缘检测算子，然后对获取到的边缘信息按照一定的规则或阈值进行筛选，排除不连续的边缘线和奇异点，最后对边缘进行链接工作从而获得光滑完整的边缘，达到分割的目的。边缘检测法有着检测速度快和计算量较小的优点，但是对存在目标边界模糊或边界断裂的图像则无法进行分割，在分割过程会产生伪边界、不连续边界以及边界丢失的情况，此外，边缘检测法也无法分割噪声图像。

（3）基于区域的图像分割算法

区域分割法是根据预先定义的相似性准则将具有同类特征的像素和区域集合起来，从而将图像划分为多个同质区域以实现分割的目的。主流的区域分割法有区域生长法和区域合并分裂法。区域生长法首先选取一部分像素点作为种子点，然后按照一定的规则将它周围邻域内与其有相同或相似特征的像素归类到该种子点所在的区域^[7]。区域生长法是一种局部到整体的方法，而区域分裂合并法则相反，是一种从整体到局部的方法，图像在提前约定好的分裂与合并的相似性准则下进行分裂或合并操作，直到所有的区域都不再满足分裂与合并条件。区域生长法具有实现简单、计算速度快等优点，但是需要人工选定种子点，且受噪声影响较大^[5]。区域分裂合并法无需人工选择种子点，但是存在分裂程度把握困难的问题。若分裂深度不足，会导致分割不准确，若增加分裂深度，那么又会导致计算成本大幅度增加。

(4) 多学科融合的新型分割算法

随着研究人员对图像处理技术不断的深入研究和应用以及多种学科的全方面发展, 数学, 物理, 生物, 人工智能以及模式识别等学科的理论知识被逐渐引入到图像分割领域, 进行优势互补, 形成多学科交叉融合的复合型算法并成为近年来图像分割算法的研究趋势, 这类算法有: 基于人工神经网络的图像分割算法、基于聚类的图像分割算法^[8,9]、基于机器学习的图像分割算法^[10]、基于水平集的图像分割算法^[11,12,13]、基于模糊理论的图像分割算法^[14,15]、基于视觉显著性的图像分割算法^[16]、基于小波变换的图像分割算法、基于马尔可夫随机场的分割算法^[17]、基于遗传算法的图像分割方法、基于数学形态学的分割算法方法等等。

在层出不穷的各类新型算法中, 基于水平集的图像分割算法凭借其独有的算法优势, 如自由拓扑变换, 多信息共融性与较好的扩展性, 强大的数学基础等成为近年来图像分割领域最受青睐和应用的方向并迅速发展^[2,18]。

1.2.2 水平集图像分割算法的优势

(1) 灵活自由的拓扑变换

演化曲线可以很自然地改变拓扑结构来适应目标边缘的变化, 如发生分裂、合并、形成尖角等, 这使其能够有效地分割具有复杂形状的目标对象来弥补其它分割方法的不足。

(2) 光滑连续的目标边界

由于水平集的速度函数是光滑的, 并且在整个演化过程中保持为有效的水平集函数, 使得轮廓曲线始终保持良好的光滑性和连续性, 从而形成封闭连续的分割线。

(3) 强大的数学理论支撑

水平集方法将整个曲线(面)的演化过程转化为偏微分方程数值求解问题, 闭合曲线(面)采用隐式表达, 避免了对具体曲线的跟踪需求, 降低了难度^[18]。此外其数值求解过程是通过离散网格的形式进行有限差分法计算, 相较于传统跟踪演化曲线时进行参数化的求解方式更加简单易行。

(4) 多信息共融性与良好的扩展性

水平集方法是一种基于图像高层先验信息的图像分割算法。在变分理论下, 可整合图像的边缘、灰度、形状、颜色、纹理等特征进行分割。同时能够有效分割三维乃至更高维的图像。

1.2.3 水平集图像分割算法

基于水平集理论的图像分割算法主要是指几何活动轮廓模型，它是水平集方法与活动轮廓模型的结合。水平集方法是由美国加州大学的 Osher 教授和 Sethian^[19]教授于 1988 年提出，其核心思想是通过一个高维函数曲面来表达低维演化曲线或曲面，在数值实现过程中利用高维水平集函数的偏微分演化方程来表征演化曲线或曲面的演化方程，以此来有效地避免曲线或曲面的参数化过程。

水平集方法提出以后，Caselle^[20]等人将这一理论引入活动轮廓模型并与 1993 年提出了基于水平集方法的几何活动轮廓模型。几何活动轮廓模型利用水平集算法的优点，将演化轮廓曲线隐式的表达为高维函数曲面的零水平集，即将研究曲线的演化转化为追踪高维水平集函数曲面的演化，摒弃了演化曲线的参数化过程，从而能够灵活自然地处理演化过程中发生的拓扑结构变化。

基于水平集方法的几何活动轮廓模型凭借其算法优势渐渐取代了参数活动轮廓模型，成为活动轮廓模型领域的主流并快速发展，目前已成为图像分割领域的中流砥柱，因此研究基于水平集方法的活动轮廓模型十分必要。通常情况下，基于水平集方法的几何活动轮廓模型主要分为边缘活动轮廓模型和区域活动轮廓模型。下面将依次介绍这两类模型。

(1) 基于边缘的活动轮廓模型

基于边缘的模型通过衡量图像的梯度信息变化构造边缘检测函数，由于图像目标边界通常伴随着灰度的急剧变化，当边缘停止函数检测到图像内梯度变化较大时，就判断曲线演化到了目标边缘于是促使曲线停止在该区域。由此可见，边缘模型适用于分割目标边界有明显灰度变化的图像。测地线活动轮廓模型（Geometric active contours, GAC）是最早提出的基于边缘的活动轮廓模型^[20]，它是由 Caselles 等人在 1993 年提出的，也是将水平集算法引入活动轮廓模型的里程碑式模型。由于 GAC 模型仅参考图像的梯度变化，所以在遇到弱边界时边缘检测函数的值较小无法使演化曲线停止下来导致容易产生过分割，而当演化曲线遇到目标凹陷程度较大的区域时，会陷入局部极小值无法继续演化。针对 GAC 模型存在的问题，研究人员提出了大量的改进模型，通过改造边缘检测函数来提高对弱边界和噪声图像的分割能力。Liu^[21]等人将图像的局部区域拟合信息引入 GAC 模型，重构了边缘停止函数中的常量因子，提出了一种改进的基于局部拟合信息的边缘模型，提高了对目标边缘和噪声点的识别能力；杨^[22]等人通过计算图像的灰色关联程度来衡量边缘的强弱程度，改进了边缘停止函数，使得演化曲线能够停止在弱

边缘处,解决了传统边缘模型仅利用梯度信息造成弱边界泄露的问题,从而提高了对弱边界图像的分割准确度。高^[23]等人将图像的先验信息与区域特征信息同时引入边缘停止函数中,提高了 GAC 模型对噪声图像以及弱边缘的分割能力。

基于边缘的活动轮廓模型根据图像梯度的变化来捕捉目标边缘,因此适用于处理具有明显边缘特征的图像,然而由于其完全依赖于目标边缘的梯度信息,在处理没有明显梯度变化的弱边缘图像时效果很不理想,而且对噪声也十分敏感。为了解决边缘模型的缺陷,研究人员提出了基于区域型的活动轮廓模型。

(2) 基于区域的活动轮廓模型

基于区域的活动轮廓模型主要利用图像的区域统计信息来构建模型。它不再单纯依赖图像的梯度信息,因此可以较好地分割边缘对比度低的图像。基于区域的模型又可以分为基于全局信息的活动轮廓模型和基于局部信息的活动轮廓模型^[24-26]。首先介绍全局活动轮廓模型。Mumford 和 Shah 于 1989 年提出的 Mumford-Shah 模型^[27]是最早的基于全局区域信息的活动轮廓模型。但是该模型计算复杂度高,且数值求解过程比较困难。针对这一问题,Chan 和 Vese 于 2001 年提出了简化的 Mumford-Shah 模型,即 C-V 模型^[28],与 Mumford-Shah 模型不同的是,C-V 模型假设原始图像目标与背景两区域的灰度呈均匀分布,并且这两个区域的平均灰度值有较大的差值,然后模型根据目标与背景区域之间灰度均值的差异来对原始图像进行分割。C-V 模型的提出极大地简化了 Mumford-Shah 模型的复杂度,具有计算复杂度低,曲线收敛速度快,对初始轮廓的位置也不敏感的优点。

C-V 模型的特点使其成为最经典的全局区域模型并沿用至今,但由于该模型是建立在目标与背景是均匀分布这一假设上,而在实际应用中,需要处理的图片灰度往往是不均匀的且分布复杂,C-V 模型过于理想化在分割这类图像时效果很差。为了提高区域模型对灰度不均匀图像的分割性能,研究学者对图像进行局域化剖析并提出了很多利用局域信息的活动轮廓模型。Li^[29]等人将邻域思想引入活动轮廓模型,提出了基于图像局部特征的局部二值拟合模型(Local binary Fitting, LBF)模型,通过核函数,该模型较好的解决了 C-V 模型不能分割灰度不均匀图像的问题,之后又在这一基础上进行改进提出了局域范围可变的 RSF 模型。Li 提出的模型由于运用了过多的卷积操作,使得计算复杂度较高,且对初始曲线的位置敏感同时容易陷入局部极小值。针对 Li 模型运算复杂度高的问题,Zhang^[30]等人提出了局部图像分割(Local image Fitting, LIF)模型,大大减小了运算量,同时保持了对灰度不均匀图像和噪声图像的分割精度,但仍然存在局部区

域模型存在的普遍问题。Wang^[31]等人提出了基于局部高斯分布拟合的活动轮廓模型 (Local Gaussian distribution fitting energy, LGDF)，该模型将高斯核函数作为密度估计函数来描述局部灰度特征，同时引入了极大后验概率，LGDF 模型利用图像的局部灰度均值与灰度方差作为方程的空间变量，从而对局部区域的描述更加全面精确，在处理灰度不均匀性图像时也表现出更好的鲁棒性。但是该模型对灰度的变化过于敏感，且计算量较大。Liu 等人提出了一种由局部直方图拟合能量项驱动的非参数局部区域模型。通过统计高斯核函数内的灰度直方图信息来近似局域内目标和背景的分布。同时引入三个不等式来调节高斯核的尺寸以适用于不同区域的分割。Wang^[32]等人在 LBF 模型的基础上进行改进，提出了一种基于局部线性分类的模型 LLC (locally linear classification)。其方法是在每个局部邻域，定义一个局部加权最小二乘能量项来拟合一个线性分类器，通过将局部线性函数引入局部区域的背景和前景，提高模型的分割准确度。此外，一些结合聚类和模糊理论的水平集分割方法也相继被提出，如 G^[33]等人提出了一种利用高斯核诱导的模糊 c-均值聚类(GKFCM)和活动轮廓模型结合的混合型分割方法。模型利用 GKFCM 方法得到的结果作为初始化轮廓，并通过 GKFCM 来估计曲线演化过程中使用到的几个控制参数。S^[14]等人结合模糊理论提出了一种基于模糊能量函数的分割模型，它包括图像区域的强度分布和模糊隶属函数的值。其中强度分布采用高斯混合模型(GMM)的强度分布估计，然后利用模糊隶属函数，对曲线内外各图像像素的关联程度进行测量。

目前，在国外研究水平集图像分割方法比较领先的团队主要有：水平集创始 Stanley Osher 教授和 James A.Sethian 教授领导的加州大学伯克利分校国家实验室数学部，CV 模型创始人 Tony Chan 教授领导的美国加州大学洛杉矶分校图像处理研究部，LBF 模型的提出者李纯明教授所在的美国范德比特大学图像科学部，以及其它研究成果众多的团队如佐治亚理工学院电子和计算机工程分院^[18]，加拿大国家科学研究院电信学系，美国路易斯维尔大学计算机视觉和图像处理实验室。

在国内研究水平集图像分割方法比较优秀的团队有：中国科学院自动化研究所复杂系统与智能科学重点实验室、上海交通大学图像处理与模式识别研究所、华中科技大学图像识别与人工智能研究所、重庆大学光电技术及系统教育部重点实验室等。

1.3 研究内容与创新

本文的主要内容是研究基于区域的水平集图像分割方法,针对现有区域模型存在的

不足之处进行了改进创新，最后结合多种人工合成图像和工程实践中的真实图像来验证模型的可行性。本文所做的创新工作总结如下：

针对现有局部模型在分割灰度不均匀图像时容易陷入局部极小值造成分割失败的现象，提出了一种改进的能够有效解决局部极小值问题的模型 VLIF。该模型结合最大类间方差思想，在 LIF 模型的基础上增加类间方差能量项，通过最大化演化曲线上所有点的邻域内目标和背景的差异来剔除使演化曲线陷入局部极小值的伪边界点，驱使演化曲线最终留在正确的目标边界。为了证明提出模型的有效性，本章进行了一系列对此实验，结果表明改进的模型可以有效地解决局部模型因陷入局部极小值而导致的误分割问题，提高对灰度不均匀以及复杂图像的分割准确度。

提出了一种权重自适应的融合图像全局信息和局部信息的活动轮廓模型。利用图像局部熵建立了精确可靠的衡量图像灰度信息的指标，通过实时获取图像分割过程中的灰度分布情况自适应的指导模型中不同功能能量项配比，实现全自动化分割。相比传统基于反复试验的固定参数线性调整模式，本文选择了一种更加量化和合理的方式实现了全局项与局部项的动态非线性调整，实现了对多种类型图像的快速准确分割。最后通过一系列实验表明本文模型对于不同类型的灰度不均匀和噪声图像，能够完成快速准确的分割，且稳定性较高，对初始轮廓的位置也不敏感。

1.4 论文结构安排

全文的组织结构分为五个部分，具体安排如下：

第一章为论文的绪论部分。本章首先阐述了本文的研究背景和意义，介绍了图像分割的概念以及各个领域中的应用和发展现状。接着对图像分割方法进行综述，首先回顾了经典的图像分割算法，之后介绍了水平集算法的优势并对目前的水平集图像分割方法进行了梳理，总结了水平集图像分割方法当前面临的主要问题确定了论文的研究方向。最后，对本文的主要工作和内容安排进行了概述。

第二章主要介绍水平集方法的相关理论知识。本章首先对曲线演化理论进行阐述，接着引出水平集方法的基本理论并给出了水平集方法的数值计算方案。最后详细的分析了几种经典的活动轮廓模型。

第三章结合最大类间方差思想提出一种有效解决局部极小值问题的活动轮廓模型。本章首先回顾了现有的比较流行的局部模型，然后分析了这些局部模型在分割灰度不均匀图像时容易陷入局部极小值造成分割失败的现象，对这一问题产生的原因进行深入剖

析，之后阐述了最大类间方差思想的基本理论，并将改思想与图像分割理论结合，提出了一个改进的能够有效解决局部极小值问题的模型 VLIF。改进的模型结合最大类间方差思想，在局部模型的基础上增加类间方差能量项，通过最大化演化曲线上所有点的邻域内目标和背景的差异来剔除使演化曲线陷入局部极小值的伪边界点，驱使演化曲线最终留在正确的目标边界。最后展示了多组对比实验，通过实验结果表明改进的模型可以有效地解决局部模型因陷入局部极小值而导致的误分割问题，提高对灰度不均匀以及复杂图像的分割准确度。

第四章结合图像熵理论提出了一种权重自适应的融合图像全局信息和局部信息的活动轮廓模型。本章首先阐述了新模型提出的背景，重点指出权重参数在指导模型能量项配比中的重要性以及现有模型无法自动选择权重参数的缺陷，然后介绍了图像熵以及局部熵的概念，并利用图像局部熵能够反映灰度信息变化的特性建立了一种精确可靠的衡量图像灰度信息的指标，自适应的指导模型中不同功能能量项配比，实现全自动化分割。最后通过一系列实验表明本文模型对于不同类型的灰度不均匀和噪声图像，能够完成快速准确的分割，且稳定性较高，对初始轮廓的位置也不敏感。

第五章为论文的总结与展望部分，首先对本文所做的工作进行总结性论述，然后对下一步的研究工作进行了展望。

第二章 水平集图像分割数学基础

2.1 曲线演化问题

曲线演化理论根据其定义是指利用曲线的几何参数通常为单位法矢量和曲率等来描述这条曲线随着时间进行几何变换的情况^[68]。其中，单位法矢量表征曲线各点的运动方向，曲率衡量曲线弯曲的程度。那么曲线演化的过程就可以描述为二维平面内的一条封闭光滑的曲线在一定时间内沿着其法线方向以一定速度进行运动^[69]。将其应用到图像分割领域，即轮廓曲线在多种信息的指导下向着目标进行收缩和扩张运动，直至到达理想的目标边界。

定义一条随时间变化的封闭光滑的平面曲线 $C(p, t)$ ， p 为曲线参数且可以取任意值，设 k 为曲线的曲率， T 和 N 分别表示曲线的切线和法线，那么曲线上任意一点的切向量和法向量有如下空间关系。

$$\frac{dC}{dp} = T \quad (2-1)$$

$$\frac{d^2C}{dp^2} = kN \quad (2-2)$$




图 2-1 曲线上任意一点的切线和法线

Fig.2-1 The tangent and normal of any point on a curve

由图可以看出，对于曲线上的任一点，其切向量和法向量都是互相垂直的，因此我们可以用切向量和法向量的线性组合来表示平面上的任意一条曲线。为了得到曲线随时间进行演化的表达式，将时间变量 t 引入，于是得到了曲线随时间变化的偏微分方程表达式为：

$$\frac{\partial C}{\partial t} = \alpha T + \beta N \quad (2-3)$$

其中， α 和 β 分别表示曲线运动速度的切向速率与法向速率，由于曲线几何形状的

变化只与法向速率 β 有关而与切向速率无关，于是曲线演化方程可简化为：

$$\frac{\partial C}{\partial t} = V N \quad (2-4)$$

其中， N 为单位法矢量，决定了曲线演化的方向， V 为曲线演化速度。当 V 的取值为正时，曲线向其内部方向运动（收缩）；当 V 取值为负时，曲线向其外部方向运动（扩张）。

如图为曲线运动示意图：




图 2-2 曲线演化示意图

Fig.2-2 Schematic diagram of curve evolution

根据速度函数 V 的不同取值，曲线演化可分为曲率演化和常量演化。

(1) 若 $V = \alpha k N$ ，曲线按曲率方式演化，其演化方程可写为：

$$\frac{\partial C}{\partial t} = \alpha k N \quad (2-5)$$

其中 $\alpha > 0$ 为常系数， k 为曲线的曲率。曲率的定义为曲线上任一点处的切线方向角沿弧长的转动率。曲率可以反映曲线的弯曲程度。曲线的演化速度随着弯曲程度的不同将呈现这样的规律：在弯曲程度较大的地方快，而在相对平缓的地方慢。因此，在曲率的作用下，曲线会逐渐演化趋近于曲率均匀的圆形最终形成一个光滑圆。

(2) 若 $V = V_0 N$ ， V_0 为常数，曲线按照常量方式演化，其演化方程为：

$$\frac{\partial C}{\partial t} = V_0 N \quad (2-6)$$

常量演化的作用机制是使得封闭曲线在演化过程中产生尖角，并可能造成曲线合并或分裂，使得曲线的拓扑结构发生较大的变化。

由此可见，曲率演化和常量演化会使曲线按照完全不同的方式变化。曲率演化会逐渐去除曲线的尖角使其趋于平滑。常量演化会使演化曲线出现尖角产生合并和分裂，造

成拓扑结构发生变化^[34]。

以上的阐述说明传统的曲线演化理论利用了曲线的曲率和法向矢量来描述曲线的几何运动，然而研究人员发现这种参数化方式存在很多问题难以解决：

(1) 曲线的演化完全依赖于参数，且曲率和法向矢量的计算十分困难和复杂；

(2) 参数方法在很多情况下无法实时跟踪曲线在演化过程中发生的合并或分裂等拓扑变化；

(3) 在对曲线演化的偏微分方程求解时，通常采用“标注质点”的方法，但这种方法往往会产生奇异性，无法获得正确的数值计算结果。

(4) 以上数值求解过程需要极小的时间步长来保证整个算法运行的稳定性。当参数点随着时间不断更新时，计算误差也会在这个过程中逐渐积累，而当这些误差积累到一定程度时，曲线演化的精度将会受到严重的影响^[70]。

为了解决这些问题，OSher 和 Sethian 于 1988 年提出了水平集方法，从此为曲线演化的研究带来了革命性的突破。

2.2 水平集理论

2.2.1 水平集基础理论

水平集方法是由 Osher^[19]和 Sethian 于 1988 年提出，这一方法的出现产生于两位学者追踪热力学方程下火苗外部轮廓线的演化过程。由于火苗轮廓线在外力作用下变化快速，且拓扑结构任意变换难以预测，研究人员无法用带参数的数学表达式来描述这种自然界复杂变化的曲线或者曲面，于是提出了水平集方法来对演化曲面进行动态描述。水平集方法的核心思想是将在低维平面上进行演化的曲线隐含地嵌入到高一维演化曲面的零水平集泛函中，然后利用高维的泛函来表示低维曲线的演化，从而将曲线演化转化为 PDE 的数值求解问题^[71]。这种低维空间向高维空间的转化过程虽然使问题的求解在表达形式上变得复杂，但是在解决很多实际场景中的棘手问题时带来了新的突破。

水平集方法的提出有效解决了对自然界事物轮廓的跟踪和形状建模等问题，该方法最大的优点是不再使用参数化方法对轮廓演化进行监视，而是在固定的笛卡尔网格上对演化曲面进行数值计算和迭代，通过这样的方式使隐含在其中的水平集曲线得以灵活自由的演化。水平集方法自问世以来就受到国内外学者的广泛重视和研究，经过多年的发展现已普及应用到多种科研领域，而图像分割就是最重要的应用之一。

水平集的核心思想是把二维平面上的演化曲线 C 嵌入到高一维的水平集函数 $\phi(C)$

中。假设 $\varphi(C(t), t)$ 为给定的随时间变化的水平集函数，那么它在 t 时刻的零水平集表达 $\varphi(C(t), t) = 0$ 即为演化曲线，然后按照复合函数链式求导法则来对方程式 $\varphi(C(t), t) = 0$ 进行求导可得：

$$\frac{\partial \varphi}{\partial t} + \nabla \varphi \cdot \frac{\partial C}{\partial t} = 0 \quad (2-7)$$

其中， $\nabla \varphi$ 为 φ 的梯度。

假设 s 是闭合曲线 C 的弧长参数，根据前面水平集函数的定义以及上一节曲线演化理论的讨论，得到 φ 沿着曲线 C 切线方向的变化量为 $\frac{\partial \varphi}{\partial s} = 0$ ，即：

$$0 = \frac{\partial \varphi}{\partial x} \frac{\partial x}{\partial s} + \frac{\partial \varphi}{\partial y} \frac{\partial y}{\partial s} = \left\langle \nabla \varphi, \frac{\partial C}{\partial s} \right\rangle \quad (2-8)$$

由 2-8 可知， $\nabla \varphi$ 垂直于切线 $\frac{\partial C}{\partial s}$ ，由此可见 $\nabla \varphi$ 和曲线 C 的法线方向是同向的。假

设水平集函数 φ 的取值在曲线内部为 $\varphi < 0$ ，在曲线外部为 $\varphi > 0$ ，那么演化曲线 C 的内

向单位法向量 $N = -\frac{\nabla \varphi}{|\nabla \varphi|}$ 。由于 $\frac{\partial C}{\partial t} = V(k)N$ ，于是得到：

$$\frac{\partial \varphi}{\partial t} = -\nabla \varphi \cdot V(k)N = V(k)|\nabla \varphi| \quad (2-9)$$

其中，

$$k = \text{div}\left(\frac{\nabla \varphi}{|\nabla \varphi|}\right) = \frac{\varphi_{xx}\varphi_y^2 - 2\varphi_{xy}\varphi_x\varphi_y + \varphi_{yy}\varphi_x^2}{(\varphi_x^2 + \varphi_y^2)^{3/2}} \quad (2-10)$$

式 2-9 是一个 Hamilton-Jacobi 类型的偏微分方程，由此可见水平集方法的本质是求解一个随时间变化的偏微分方程的过程。它包含一个超曲面的隐式数据表达、一个能指导曲面演化的偏微分方程组以及相对应的数值计算方案。

2.2.2 水平集的数值计算

水平集函数的求解过程实质上是对偏微分方程求极值的过程。通常采用有限差分法，有限元法，谱法等来对偏微分方程进行数值求解。在图像处理领域，通常使用有限差分法，这是因为图像本身在二维空间中的存在形式是按等间隔采样的离散化数据，从而为有限差分法所需要的等分网格提供了自然条件。

接下来对水平集函数 $\varphi(x, y, t)$ 进行离散化求解。对于大小为 $M \times N$ 的二维图像 $I(x, y)$ ，像素点为 (i, j) ，其中 $i = 1, 2, \dots, M$ ， $j = 1, 2, \dots, N$ 。设定离散网格的间距即空间

步长为 h ，时间步长为 Δt ，离散水平集函数在 n 时刻在图像网格点 (i, j) 处的水平集函数可表示为 $\varphi_{i,j}^n$ ，则水平集演化方程 2-9 的离散化形式为：

$$\frac{\varphi_{ij}^{n+1} - \varphi_{ij}^n}{\Delta t} = F_{ij}^n |\nabla \varphi_{ij}^n| \quad (2-11)$$

其中， F_{ij}^n 表示速度函数 n 时刻在图像网格点 (i, j) 处的值。为了避免以上 Hamilton-Jacobi 方程产生奇异性，将采用迎风有限差分法 (upwind finite differential method) 进行稳定求解^[35]。水平集函数的演化方程 2-11 可表示为：

$$\varphi_{ij}^{n+1} = \varphi_{ij}^n + \Delta t (\max(F_{ij}^n, 0) \nabla^+ + \min(F_{ij}^n, 0) \nabla^-) \quad (2-12)$$

其中，

$$\nabla^+ = [\max(\varphi_x^-, 0)^2 + \min(\varphi_x^+, 0)^2 + \max(\varphi_y^-, 0)^2 + \min(\varphi_y^+, 0)^2]^{1/2} \quad (2-13)$$

$$\nabla^- = [\max(\varphi_x^+, 0)^2 + \min(\varphi_x^-, 0)^2 + \max(\varphi_y^+, 0)^2 + \min(\varphi_y^-, 0)^2]^{1/2} \quad (2-14)$$

以上计算过程中需要的中心差分算子以及向前、向后差分算子的一阶计算公式为：

$$\varphi_x^0 = \frac{1}{2h} (\varphi_{i+1,j} - \varphi_{i-1,j}) \quad \varphi_y^0 = \frac{1}{2h} (\varphi_{i,j+1} - \varphi_{i,j-1}) \quad (2-15)$$

$$\varphi_x^+ = \frac{1}{h} (\varphi_{i+1,j} - \varphi_{i,j}) \quad \varphi_y^+ = \frac{1}{h} (\varphi_{i,j+1} - \varphi_{i,j}) \quad (2-16)$$

$$\varphi_x^- = \frac{1}{h} (\varphi_{i,j} - \varphi_{i-1,j}) \quad \varphi_y^- = \frac{1}{h} (\varphi_{i,j} - \varphi_{i,j-1}) \quad (2-17)$$

至此，水平集函数在方程 2-12 的迭代下不断更新，从而实现了曲线的演化。在这个过程中，由于采用了有限差分算法，如何选取合理的时间步长 Δt 至关重要，它能够确保水平集函数稳定的演化并收敛。在固定空间步长 h 的情况下，时间步长 Δt 应满足如下 CFL (Courant-Friedrichs-Levy) 条件：

$$F_{MAX} \cdot \Delta t < h \quad (2-18)$$

其中， F_{MAX} 表示二维平面内所有点的最大移动速度，由此可见，零水平集在每次迭代的过程中，最大移动距离必须小于等于一个网格宽度来保证其稳定演化。

2.3 经典的活动轮廓模型

活动轮廓模型是一种结合曲线演化理论和偏微分方程的图像分割方法。其核心理论是定义一条封闭光滑的闭合曲线作为初始轮廓，然后使这条初始轮廓曲线在驱动力的作用下朝着目标边缘不断演化，直到轮廓曲线演化到目标的边界，完成提取目标边界的任务。在这个过程中，指导轮廓曲线进行演化的驱动力分为内力和外力。其中，外力源自

于图像本身所包含的信息，其作用是吸引和驱动轮廓曲线向目标边界演化。内力源自于曲线自身，其作用是约束曲线的弹性形变，保证轮廓曲线在演化的过程中维持规则和光滑状态。

活动轮廓模型的数值实现原理是将图像分割问题看成是一个求解代表曲线演化的能量泛函的极小值。首先构建一个基于图像信息的能量泛函，然后利用变分原理将求解泛函极小值的问题转换为一个求解偏微分方程的问题，通常采用有限差分法对偏微分方程进行离散化求解，最后得到图像分割的结果，即能够对图像进行正确分割的演化曲线。活动轮廓模型根据研究原理的不同又可以分为参数活动轮廓模型和基于水平集的几何活动轮廓模型。

2.3.1 参数活动轮廓模型

参数活动轮廓模型简称蛇(Snake)模型，它是由 Kass^[38]于 1987 年提出，其研究原理是首先在目标区域附近给出一条初始轮廓曲线，然后依据图像信息和曲线自身演化的特征建立能量泛函，使这条轮廓曲线在以图像信息为外部能量项和曲线自然发生弹性形变的力量为内部能量项的作用下向目标边界逼近，直到准确地停止在目标边缘。接下来对这一过程进行详细化描述：

首先，采用归一化的弧长参数 s 来对初始轮廓曲线 C 进行参数化表达得到： $C(s)=[x(s),y(s)],s\in[0,1]$ 。然后建立轮廓曲线 $C(s)$ 的能量泛函 $E(C(s))$ ：

$$E(C(s)) = E_{\text{internal}} + E_{\text{external}} \quad (2-19)$$

其中， E_{internal} 是基于曲线几何特征的内部能量项，它的作用是保证曲线在整个演化过程中一直是光滑和连续的，它由连续项和光滑项两部分组成：

$$\begin{aligned} E_{\text{internal}}(C(s)) &= \alpha(s)E_{\text{continuity}} + \beta(s)E_{\text{smoothness}} \\ &= \frac{1}{2} \int_0^1 \left[\alpha(s) \left| \frac{\partial C}{\partial s} \right|^2 + \beta(s) \left| \frac{\partial^2 C}{\partial^2 s} \right|^2 \right] ds \end{aligned} \quad (2-20)$$

第一项用来控制曲线的连续性，由曲线 C 的一阶导数得到曲线的斜率，然后在弹力系数 $\alpha(s)$ 的作用下控制曲线以较快或较慢的速度形变；第二项的作用是控制曲线的弯曲程度，由曲线 C 的二阶导数得到曲线的曲率，在强度系数 $\beta(s)$ 的作用下控制曲线沿法线方向的演化速率。

E_{external} 是基于图像的固有信息如梯度等构成的外部能量项，其目的是为轮廓曲线向目标边界演化提供驱动力，一般情况下，外部能量项可取为。

$$E_{\text{external}}(C(s)) = -|\nabla I(x,y)|^2 \quad (2-21)$$

$$E_{external}(C(s)) = -\|\nabla G_\sigma * I(x, y)\|^2 \quad (2-22)$$

其中, ∇ 为梯度算子, G_σ 是标准差为 σ 的高斯核函数, $G_\sigma * I$ 为图像 $I(x, y)$ 与高斯核函数的卷积。

于是, 得到参数活动轮廓模型的最终能量泛函表达式为:

$$E(C(s)) = \frac{1}{2} \int_0^1 \left[\alpha(s) \left| \frac{\partial C}{\partial s} \right|^2 + \beta(s) \left| \frac{\partial^2 C}{\partial s^2} \right|^2 \right] ds + \int_0^1 E_{external}(C(s)) ds \quad (2-23)$$

我们发现在这个过程中, 参数活动轮廓模型的能量泛函 $E(C(s))$ 始终依赖于参数 s , 因此限制了曲线的灵活形变, 此外参数化的方式使得数值实现极其耗时。

参数活动轮廓模型是当时图像分割领域一种开创新的方法, 但是存在的缺陷限制了进一步推广和应用。如对初始轮廓的位置和形状敏感、无法灵活地处理曲线的拓扑结构变化, 数值计算复杂, 容易陷入局部极小值以及无法分割凹陷形状的图像。为了解决参数活动轮廓模型分割的不足, 研究人员提出了意义重大且沿用至今的几何活动轮廓模型。

2.3.2 GAC 模型

测地线活动轮廓(Geodesic active contour, GAC)模型最早将水平集方法引入到活动轮廓模型中, 也是最具代表性的边缘模型, 其能量泛函定义如下:

$$E_{GAC}(C) = \int_0^{L(C)} g(|\nabla I(C(p))|) dp \quad (2-24)$$

其中 $L(C)$ 表示曲线 C 的周长, g 为边界停止函数, 其表达式如下:

$$g(|\nabla I|) = \frac{1}{1 + \|\nabla G_\sigma * I(x, y)\|^2} \quad (2-25)$$

其中, $G_\sigma * I$ 表示图像 I 和标准差为 σ 的高斯核函数 G_σ 的卷积, 根据变分法, 得到式 2-24 的梯度下降流如下:

$$\frac{\partial C}{\partial t} = g(|\nabla I|) k N - (\nabla \cdot N) N \quad (2-26)$$

其中 k 表示曲线 C 的曲率, N 是曲线 C 的内向法向量。将曲线 C 替换成水平集函数得到 GAC 模型水平集的演化方程为:

$$\frac{\partial \phi}{\partial t} = g|\nabla \phi| \cdot \operatorname{div} \left(\frac{\nabla \phi}{|\nabla \phi|} \right) + \nabla g \cdot \nabla \phi \quad (2-27)$$

GAC 模型作为边缘模型能够灵敏的捕捉目标边界的梯度变化, 可以较好的分割边

界对比度较强的图像，但是这也意味着模型对噪声非常敏感，在遇到噪声时会表现的不稳定，此外初始轮廓的位置和大小对分割结果的影响也很大。

2.3.3 Mumford-Shah 模型

Mumford-Shah 模型是最早提出的基于图像区域信息的活动轮廓模型简称 M-S 模型，其能量泛函由三部分构成：图像数据逼近项，图像区域平滑项，分割曲线长度惩罚项。其核心思想是对于定义在平面 $\Omega \subset R^2$ 上的图像 I ，寻找一对 (u, C) 。其中 $u(x, y)$ 是对图像 I 的分段光滑拟合， C 为光滑且闭合的轮廓线，那么得到分割模型能量泛函表示如下：

$$E_{MS}(u, C) = \int_{\Omega} |I(x, y) - u(x, y)|^2 dx dy + \mu \int_{\Omega \setminus C} |\nabla u(x, y)|^2 dx dy + \nu \cdot \text{Length}(C) \quad (2-28)$$

其中 μ 和 ν 是非负常数。第一项为数据驱动项，它的作用是使演化曲线逼近目标边缘。第二项为平滑项，可以确保演化曲线处处光滑。第三项为长度约束项，用于约束分割轮廓线的长度，保证边界的光滑。

Mumford-Shah 模型的数值求解过程计算量很大且比较复杂，而如果精简 $E_{MS}(u, C)$ 中的能量项，那么又会出现拟合图像与曲线形成平凡解的现象，因此 Mumford-Shah 模型并不能在实践中得到很好的应用。因此 Chan 和 Vese 在 Mumford-Shah 模型的基础上做了一定简化，建立了基于水平集的全局模型 C-V 模型，并得到了广泛的应用。

2.4 本章小结

本章详细阐述了水平集图像分割算法的基础理论。首先介绍了曲线演化理论，在这个基础上引出了水平集的概念，然后对水平集理论进行了详细的论述，并给出了水平集的数值求解过程，最后介绍了几种经典的水平集图像分割模型：参数活动轮廓模型简称蛇(Snake)模型，测地线活动轮廓(Geodesic active contour, GAC)模型和 Mumford-Shah 模型。

第三章 基于最大类间方差的局部分割模型

本章将研究局部模型在分割灰度不均匀以及场景复杂的图像时容易陷入局部极小值的问题。首先对这一问题产生的原因进行深入剖析并提出了一个改进的能够有效解决局部极小值问题的模型 VLIF (Maximum Between-cluster Variance Local Image Fitting, VLIF)。该模型结合最大类间方差思想,在 LIF 模型的基础上增加类间方差能量项,通过最大化演化曲线上所有点的邻域内目标和背景的差异来剔除使演化曲线陷入局部极小值的伪边界点,驱使演化曲线停留在正确的目标边界。为了证明提出模型的有效性,本章进行了一系列对此实验,结果表明改进的模型可以有效地解决局部模型因陷入局部极小值而导致的误分割问题,提高对灰度不均匀以及场景复杂图像的分割准确度。

3.1 研究背景

基于图像局部信息的分割模型^[39-45]相较于全局模型可以更加有效的分割灰度不均匀信息,多年来受到国内外学者的广泛研究。如 Li^[29]等人提出基于图像局部信息的局部二值拟合模型(Local binary Fitting,LBF)模型,克服了 C-V 模型分割灰度不均匀图像的不足,但其算法复杂度较高,同时易陷入局部极小值。针对 LBF 模型计算复杂度高的问题,Zhang^[30]等人提出了局部图像拟合(Local image Fitting,LIF)模型,有效减小了运算量,同时保持了对灰度不均匀图像和噪声图像的分割精度,但在分割一些较复杂的灰度不均匀图像时仍然存在误分割问题。黄^[39]等人在 LBF 模型里增加了由图像梯度信息构成的加速因子和相似度局部拟合构成的相似项,进一步提高对图像分割的速度和准确度,但是引入梯度信息使得模型运算量很大且分割复杂图像时表现不理想。林^[44]等人根据图像灰度信息的变化提出了局部窗口动态选择的 RSF 模型,然而该模型利用边缘检测函数来衡量灰度信息变化,对噪声十分敏感且模型运行缓慢。Ji^[45]等人将最大似然思想引入局部分割模型,提出了局部似然能量拟合模型(local likelihood image fitting energy, LLIF),在构建基于图像分布的似然函数能量项时,增加了方差信息,这样模型可通过灰度均值信息和方差信息更加详细地描述图像的局部特征,从而进一步提高了对灰度不均匀图像的分割性能。

以上模型虽然采用了不同的方法对局部模型进行了改进,但在构建主能量泛函时本

质都是依赖于原始图像与拟合图像的差异，而对局部邻域内不同区域的灰度值的变化考虑不足，因此曲线在演化时容易陷入局部极小值，造成分割不准确。本文将全面考察同一像素点局部邻域内不同区域的像素灰度差异，结合最大类间方差的思想，通过最大化邻域内位于演化曲线内外的拟合灰度值的差异构建最大类间方差项，提高模型对局部极小值点的识别能力，驱使演化曲线越过伪边界点，获得正确的分割结果。

3.2 相关模型

3.2.1 RSF 模型

为了提高对灰度不均图像的分割性能，Li^[29]等人从分析图像局部邻域内灰度值变化的角度出发，提出了局部二值拟合模型（Local binary Fitting, LBF），并在此基础上加以改进，提出了局域可变的拟合模型（region-scalable fitting, RSF），该模型定义了两个拟合函数来分别近似局域图像在演化曲线内部区域和外部区域的灰度值，并引入高斯函数，通过调节高斯核函数的窗口大小来实现局域可变^[46]，RSF 模型的能量泛函定义如下。

对于目标图像 $I: \Omega \rightarrow R^2$ ，假设闭合曲线 C 将整个图像域 Ω 分割为两个子区域： $\Omega_1 = \text{inside}(C)$ 和 $\Omega_2 = \text{outside}(C)$ ，那么对图像中任意一个像素点 x ，定义如下局部灰度拟合（local intensity fitting）能量泛函：

$$\varepsilon_x^{\text{Fit}}(C, f_1(x), f_2(x)) = \sum_{i=1}^2 \lambda_i \int_{\Omega_i} K(x-y) |I(y) - f_i(x)|^2 dy \quad (3-1)$$

其中， λ_1 和 λ_2 为非负常量， $I(y)$ 为 x 邻域内的像素点， $f_1(x)$ 和 $f_2(x)$ 分别为邻域内位于演化曲线内部区和外部区的拟合灰度加权平均值， K 为控制邻域大小的窗口可变的高斯核函数，其表达式为：

$$K = K_\sigma(u) = \frac{1}{(2\pi)^{n/2} \sigma^n} e^{-|u|^2 / 2\sigma^2}, (\sigma > 0) \quad (3-2)$$

其中， σ 为控制高斯核函数窗口大小的参数，通常称为尺度参数。

泛函 $\varepsilon_x^{\text{Fit}}(C, f_1(x), f_2(x))$ 计算的是像素点 x 邻域内的情况，它的值依赖于像素点邻域内拟合均值 f_i 与 $I(y)$ 的差值。当像素点 x 位于目标边界时， f_i 的值逼近与 $I(y)$ 的值，此

时 ε_x^{Fit} 取得极小值。为了获得图像最终分割曲线，考虑整个图像域 Ω 内所有像素点的情况，需要将所有像素点的局部能量泛函进行累加，得到全局的能量泛函表达式如下：

$$E_{RSF}(C, f_1(x), f_2(x)) = \int_{\Omega} \varepsilon_x^{Fit}(C, f_1(x), f_2(x)) dx + \nu |C| \quad (3-3)$$

3.2.2 LIF 模型

RSF 模型在求解拟合函数和数据能量项时进行了双重卷积运算，导致模型计算消耗很大，为了解决这一问题，Zhang 等人提出了局部图像拟合模型(Local image Fitting, LIF)，该模型提出了一个创新性的局部能量拟合项来逼近原始图像灰度值。

首先，利用分片光滑函数来近似拟合待分割图像，该局部拟合函数(local fitted image, LFI)定义为：

$$I^{LFI} = m_1 H_{\varepsilon}(\varphi) + m_2 (1 - H_{\varepsilon}(\varphi)) \quad (3-4)$$

其中， $H_{\varepsilon}(\varphi)$ 为 Heaviside 函数，假设水平集函数 φ 在演化曲线内部小于零，在演化曲线 C 外部大于零，那么 m_1 和 m_2 分别表示为像素点 x 邻域（高斯窗）内位于曲线 C 内部和外部的灰度拟合加权平均值，即：

$$m_1 = \text{mean}(I \in (\{x \in \Omega \mid \varphi(x) < 0\} \cap W_k(x))) \quad (3-5)$$

$$m_2 = \text{mean}(I \in (\{x \in \Omega \mid \varphi(x) > 0\} \cap W_k(x))) \quad (3-6)$$

其中， W_k 在数值实现时为矩形窗口函数，本文采用了标准的高斯窗口 $K_{\sigma}(x)$ ，其尺寸为 $(4k+1)(4k+1)$ ，标准差 σ 为尺寸参数，用于调节高斯窗口大小， k 为小于 σ 的最大整数。

对于图像中的任意一点 x ，通过最小化原始图像与拟合图像的差异，得到 LIF 模型总的能量泛函如下：

$$E^{LIF}(\varphi) = \frac{1}{2} \int_{\Omega} |I(x) - I^{LFI}(x)|^2 dx, x \in \Omega \quad (3-7)$$

LIF 模型相较于 RSF 模型，在有效减小计算量的同时，仍旧保持了对灰度不均匀图像和噪声图像的分割精度，但是同其他局部分割模型一样，LIF 模型只考虑局部拟合图

像与原始图像的灰度差异，而对局部邻域内空间与灰度值的变化考虑不足，因此容易陷入局部极小值，在处理一些灰度不均匀图像时还是存在一定的局限性，会出现误分割现象，为了解决这一问题，首先对局部模型容易陷入极小值的原因进行分析。

由前面的论述可知，LIF 模型改进了 LBF 模型计算量较大的缺点，同时保持了对灰度不均匀图像的分割精度，是一种比较高效的分割模型。但是 LIF 模型同 LBF 模型一样，只考虑了局部拟合图像与原始图像的灰度差异，由公式 3-7 可知，LIF 模型能量泛函的极小化仅依赖于代表拟合图像的数据项 $I^{LFI}(x)$ 和代表原始图像的数据项 $I(x)$ 的差值。其中，由公式 3-4 可知，拟合图像 $I^{LFI}(x)$ 的值由邻域（高斯窗）位于演化曲线内部和外部的拟合值 m_1 和 m_2 组成，于是我们可以得到 LIF 模型数据建模的实质上是极小化邻域（高斯窗）位于演化曲线内部和外部的拟合值 m_1 和 m_2 与原始图像的灰度差异。如图 3-1 为 LIF 模型对灰度不均匀图像的分割结果，其中，(a)为原始图像与初始轮廓，(b)为最终分割结果。由图可见 LIF 模型在当前的初始化下会陷入局部极小值，造成误分割，下面对这一现象进行分析。




图 3-1 LIF 模型对一幅灰度不均匀图像的分割

（红色曲线为演化的分割曲线， x_1 ， x_2 ， x_3 分别为演化曲线上的像素点，黑色圆圈为以像素点为中心的邻域，邻域内白色区域与蓝色区域分别为 m_1 和 m_2 代表的区域）

Fig.3-1 Segmentation result of LIF model on the image with intensity inhomogeneity

(The red curve is the segmented curve, x_1 , x_2 , x_3 are pixels on the evolution curve, the black circle is the neighborhood around the pixels, and the white area and the blue area in the neighborhood are the regions represented of m_1 and m_2 respectively.)

假设像素点 x 所在邻域内原始图像目标像素灰度用 I_1 表示, 背景像素灰度用 I_2 表示, 那么图 3-1 中, 对于 x_1 像素点, $x_1 | m_1 = 154.12, m_2 = 148.45$, $x_1 | I_1 = 158, I_2 = 142$; 对于 x_2 像素点, $x_2 | m_1 = 66.78, m_2 = 67.86$, $x_2 | I_1 = 66, I_2 = 70$; 对于 x_3 像素点, $x_3 | m_1 = 159.63, m_2 = 103.88$, $x_3 | I_1 = 160, I_2 = 102$ 。现在根据获取到的像素灰度值来分析能量泛函的变化与边界点判定机制。按照 LIF 模型的定义, 当某点处拟合均值 m_1 , m_2 与原始图像 I_1 , I_2 的差异最小时, 该点的能量泛函达到最小, 由此判定该点为边界点。在 x_3 像素点, 拟合均值 $m_1 = 159.63$, $m_2 = 103.88$ 和分别接近原始图像目标像素 $I_1 = 160$ 和背景像素 $I_2 = 102$, 即 $x_3 | m_1 \approx I_1, m_2 \approx I_2$, 那么根据 LIF 模型的定义, x_3 点处的能量泛函取得最小值, 由此判定该点为边界点。但是对于伪边界点 x_1 和 x_2 , 这样的情况同样存在。在 x_1 像素点处, 拟合均值 $m_1 = 154.12$ 和 $m_2 = 148.45$ 分别接近 $I_1 = 158$ 和 $I_2 = 142$, 那么 x_1 点处的能量泛函同样取得最小值, 于是模型判定该点也为边界点。同理, 在 x_2 像素点处, 也存在 $x_2 | m_1 \approx I_1, m_2 \approx I_2$, 能量泛函最小的情况。由此可见, 单纯依靠拟合图像与原始图像的差值来判断边界点的算法极容易导致模型陷入局部极小值, 产生伪边界点, 造成误分割。为了解决这个问题, 我们需要探索正确边界点与伪边界点的区别, 从而找到一种新的判断机制来进行二者的区分, 由此来排除伪边界点, 获得正确的分割结果。

在寻找到 LIF 模型容易陷入局部极小值产生原因的基础上, 我们进一步分析发现。当演化曲线恰好落在目标边界时, 如 x_3 点, 该点邻域内位于演化曲线内部和外部的拟合均值 m_1 和 m_2 差值很大; 当演化曲线位于背景处或目标内部时, 如 x_1 和 x_2 点, 像素点邻域内位于演化曲线内部和外部的拟合均值 m_1 和 m_2 的差异较小。由正确边界点 x_3 与伪边界点 x_1 和 x_2 的区别可得知, 对于图像中的任意一点, 在满足拟合图像 $I^{LIF}(x)$ 和原始图像 $I(x)$ 差值较小的条件下, 即 $x | m_1 \approx I_1, m_2 \approx I_2$ 的条件下, 不能将其作为唯一判断该点是否为正确边界点的依据, 必须同时满足该点 m_1 和 m_2 差值较大, 才能判断该点为边界点。

由此可见, 通过增加一个判定像素点邻域内位于演化曲线内部和外部的拟合均值的差异大小可以有效检索出伪边界点, 提高模型的分割准确度。由于最大类间方差思想可以有效衡量两类间的离散度, 这一思想与本文需求的判断机制吻合, 于是本文将最大类间方差的思想引入 LIF 模型, 通过增加类间方差项来评估像素点邻域内 m_1 和 m_2 差值, 辨别真伪边界点, 实现正确分割。

3.2.3 最大类间方差思想

最大类间方差^[47]可以有效衡量两类间的离散度, 其核心思想是根据图像的灰度特性,

将图像分为目标和背景两部分，在取得最佳阈值时，目标和背景两类间的方差最大。对于一幅给定大小的图像 $M_x \times N_y$ ，且图像的灰度级为 $[0, 1, \dots, L-1]$ ，假设灰度级为 i 的像素

点出现的次数为 h_i ，那么灰度级为 i 的像素点出现的概率 $p_i = \frac{h_i}{M_x \times N_y}$ ，最大类间方差

的思想是使用一个阈值 T ，将图像的灰度级分为目标 $[0, 1, \dots, T]$ 和背景 $[T+1, \dots, L-1]$ 两部分，其中，假设属于目标的像素点数占整幅图像像素点数的比值记为 ω_0 ，其灰度均值为 μ_0 ；

属于背景的像素点数占整幅图像像素点的比值为 ω_1 ，其灰度均值为 μ_1 ；整个图像灰度值

的平均值记为 μ ，定义最大类间方差为 σ^2 ，则有：

$$\omega_0 = \sum_{i=0}^T p_i, \quad \omega_1 = \sum_{i=T+1}^{L-1} p_i \quad (3-9)$$

$$\text{且 } \omega_0 + \omega_1 = 1 \quad (3-10)$$

$$\mu_0 = \sum_{i=0}^T i p_i / \omega_0 \quad (3-11)$$

$$\mu_1 = \sum_{i=T+1}^{L-1} i p_i / \omega_1 \quad (3-12)$$

$$\mu = \sum_{i=0}^{L-1} i p_i \quad (3-13)$$

$$\text{则有： } \mu = \omega_0 \mu_0 + \omega_1 \mu_1 \quad (3-14)$$

$$\text{又 } \sigma^2 = \omega_0 (\mu_0 - \mu)^2 + \omega_1 (\mu_1 - \mu)^2 \quad (3-15)$$

将 3-15 代入 3-14 得最大类间方差的表达式为：

$$\sigma^2 = \omega_0 \omega_1 (\mu_0 - \mu_1)^2 \quad (3-16)$$

由此可见最大类间方差思想是在图像的灰度级层使用最佳阈值 T 将整个图像分为目标和背景两部分。而对于水平集图像分割，是在图像的几何层利用光滑的演化曲线将图像分割为目标和背景两部分，虽然二者作用的基层不一样，但都是将图像看成二分类问题将目标和背景进行分类。在利用水平集理论进行图像分割的过程中，由于图像的灰度不均匀性往往会导致误分割，即将目标误分割为背景或背景被误分割为目标，而最大类间方差通过最大化目标和背景的差异来有效减少误分割。于是在该思想的启发下，本

文将两者结合，把水平集图像分割中的演化曲线等价于阈值 T ，提出基于最大类间方差的活动轮廓模型。

3.3 基于最大类间方差的 VLIF 模型

由 3.2.2 小节中对 LIF 模型在图像分割中的局限性分析可知，导致模型容易陷入局部极小值的主要原因是模型在构建时仅依赖于拟合图像与原始图像的灰度差异，通过对真伪边界点的深入分析发现，若同时考虑像素点邻域内位于演化曲线内部和外部的拟合均值的差异，当二者差异达到最大，才是正确的边界点，伪边界点并不满足这一条件。于是本文将增加一个判定像素点邻域内位于演化曲线内部和外部的拟合均值差异大小的能量项来过滤不满足这一条件的伪边界点。由 3.2.2 小节可知，最大类间方差方法可以有效衡量两类间的离散度，当两类间的方差最大时，系统得到最好的分类效果。因此使邻域内位于演化曲线内部和外部的拟合均值 m_1 和 m_2 两类间的方差最大化，可以有效地去除使演化曲线陷入局部极小值的伪边界点，解决图像的误分割现象。于是，在最大类间方法思想的启发下，本文将类间方差项引入 LIF 模型，提出基于最大类间方差的 VLIF 模型(Maximum Between-cluster Variance Local Image Fitting, VLIF)，综合考虑邻域内位于演化曲线内部和外部的拟合均值两类间的差异来减少误分割，提高分割准确度。根据最大类间方差的计算思想^[47-48]，局部高斯窗口内两类均值 m_1 和 m_2 的类间方差为：

$$\sigma_0^2 = \omega_1(m_1 - m_0)^2 + \omega_2(m_2 - m_0)^2 \quad (3-17)$$

其中， ω_1 和 ω_2 分别表示图像中分别属于 m_1 的部分和 m_2 的部分占整个图像的比值。 ω_2 表示高斯窗内像素的平均灰度值，有：

$$m_0 = \omega_1 m_1 + \omega_2 m_2 (m_0 \in \Omega_0) \quad (3-18)$$

将 3-18 代入 3-17 化简可得类间方差项：

$$\sigma_0^2 = \omega_1 \omega_2 (m_1 - m_2)^2 \quad (3-19)$$


假设邻域用 Ω_x 表示，那么类间方差能量项可定义为：

$$E_{\Omega_x}(x) = -\omega_1 \omega_2 \int_{\Omega_x} |m_1 - m_2|^2 dx \quad (3-20)$$

将类间方差项融合到 LIF 模型得到改进的 VLIF 模型的能量泛函为：

$$E^{VLIF}(\varphi) = \frac{1}{2} \int_{\Omega} |I(x) - I^{LFI}(x)|^2 dx - \omega_1 \omega_2 \int_{\Omega_x} |m_1 - m_2|^2 dx \quad (3-21)$$

如图 3-2 为改进后的模型对陷入局部极小值的演化曲线进行修正的示意图。对于 x_1 点和 x_2 点, 由于 m_1 和 m_2 的类间方差很小, 类间能量项 $E_{\Omega_x}(x)$ 在 x_1 点和 x_2 没有达到最小, 于是在新能量项的驱动下, 演化曲线会继续向目标边缘 (箭头所指方向) 运动, 直到准确地停留在目标边界。而 x_3 点处 m_1 和 m_2 的类间方差很大, 使得类间能量项达到最小, 于是新的能量项将确保该点停留在当前正确的边界处。



(a) 类间方差项修正局部极小值示意图 (b) 改进模型最终分割结果

图 3-2 本文模型对灰度不均匀图像的分割

Fig.3-2 Segmentation result of our model on the image with intensity inhomogeneity

3.4 能量泛函求解

根据水平集思想, 将演化曲线嵌入水平集函数后, m_1 和 m_2 的表达式变为:

$$m_1 = \frac{K_{\sigma}(x) * [H_{\varepsilon}(\varphi(x))I(x)]}{K_{\sigma}(x) * H_{\varepsilon}(\varphi(x))} \quad (3-22)$$

$$m_2 = \frac{K_{\sigma}(x) * [(1 - H_{\varepsilon}(\varphi(x)))I(x)]}{K_{\sigma}(x) * (1 - H_{\varepsilon}(\varphi(x)))} \quad (3-23)$$

根据式(3-14)和(3-15)以及 Heaviside 函数的性质, 图像中属于 m_1 的部分所占的比值是 $H_{\varepsilon}(\varphi(x))$, 属于 m_2 的部分所占的比值是 $(1 - H_{\varepsilon}(\varphi(x)))$, 于是表示 m_1 和 m_2 占比的 ω_1 和 ω_2 表示为:

$$\omega_1 = H_{\varepsilon}(\varphi(x)) \quad (3-24)$$

$$\omega_2 = 1 - H_\varepsilon(\varphi(x)) \quad (3-25)$$

于是得到水平集演化的泛函表达式为：

$$E^{VLIF}(\varphi, m_1, m_2) = \frac{1}{2} \int_{\Omega} |I(x) - I^{LFI}(x)|^2 dx - \int_{\Omega} H_\varepsilon(\varphi(x))(1 - H_\varepsilon(\varphi(x))) |m_1 - m_2|^2 dx \quad (3-26)$$

水平集函数随着演化进程会渐渐偏离符号距离函数，造成曲线演化不稳定，需要周期性的用符号距离函数将水平集函数再次初始化。因此加入能够自动维持 φ 函数符号距离的正则项^[49]：

$$P(\varphi) = \int_{\Omega} \frac{1}{2} (|\nabla \varphi(x)| - 1)^2 dx \quad (3-27)$$

此外，为了确保演化曲线在分割过程中尽可能保持着短而平滑的状态，需要加入演化曲线的长度惩罚项：

$$L(\varphi) = \int_{\Omega} \delta_\varepsilon(\varphi) |\nabla \varphi| dx \quad (3-28)$$

那么，本文模型的最终能量泛函可表示为：

$$E(\varphi, m_1, m_2) = E^{VLIF} + \nu L(\varphi) + \mu P(\varphi) \quad (3-29)$$

根据变分法和标准梯度下降流，得到关于水平集演化的表达式如下：

$$\begin{aligned} \frac{\partial \varphi}{\partial t} = & \delta_\varepsilon(\varphi) \left((I - I^{LFI})(m_1 - m_2) - (1 - 2H_\varepsilon(\varphi(x))) |m_1 - m_2|^2 \right) + \\ & \nu \delta_\varepsilon(\varphi) \operatorname{div} \left(\frac{\nabla \varphi}{|\nabla \varphi|} \right) + \mu \left(\nabla^2 \varphi - \operatorname{div} \left(\frac{\nabla \varphi}{|\nabla \varphi|} \right) \right) \end{aligned} \quad (3-30)$$

$H_\varepsilon(\varphi)$ 和 $\delta_\varepsilon(\varphi)$ 分别为 Heaviside 函数和它的一阶导 Dirac 函数^[50]：

$$H_\varepsilon(x) = \frac{1}{2} \left[1 + \frac{2}{\pi} \arctan\left(\frac{x}{\varepsilon}\right) \right] \quad (3-31)$$

$$\delta_\varepsilon(x) = H'_\varepsilon(x) = \frac{1}{\pi} \frac{\varepsilon}{\varepsilon^2 + x^2} \quad (3-32)$$

在数值求解过程中，为了对水平集的演化方程进行快速稳定的求解，根据第二章的论述，采用有限差分法对本章公式 3-29 中定义的水平集演化方程进行求解。所有的空间导数都被简单地离散为中心有限差分，而时间导数则被离散为正向差分^[51]。式 3-29 的逼近可离散化如下：

$$\phi_{i,j}^{n+1} = \phi_{i,j}^n + \Delta t \cdot Q(\phi_{i,j}^n) \quad (3-33)$$

有限差分法的原理是将图像离散化为等间隔网格，然后利用相邻点的数值之差与该相邻点间的距离的比值来近似表示函数的偏导数。在二维图像空间中，使用离散网格的形式来表示水平集 $\phi(x,y,t)$ ，假设离散网格中网格间隔为 h ，时间步长为 Δt ，则水平集函数的演化方程将按照如下的方式进行更新：

$$\frac{\phi_{i,j}^{n+1} - \phi_{i,j}^n}{\Delta t} = L(\phi_{i,j}^n) \quad (3-34)$$

其中 $L(\phi_{i,j}^n)$ 是水平集演化的数值逼近，等价于水平集演化方程 3-30 右边的值。

在水平集演化的偏微分方程中，首先利用中心差分法来求取一阶导数的近似：

$$\phi^x = \frac{\phi_{i+1,j} - \phi_{i-1,j}}{2h}, \quad \phi^y = \frac{\phi_{i,j+1} - \phi_{i,j-1}}{2h} \quad (3-35)$$

对于偏微分方程中的二阶导数，可以先求出两个半点处（相邻点之间）的一阶偏导数，然后对计算得到的一阶偏导数作中心差分：

$$\phi_{xx} = \frac{\phi_{i+1,j} + \phi_{i-1,j} - 2\phi_{i,j}}{h^2}, \quad \phi_{yy} = \frac{\phi_{i,j+1} + \phi_{i,j-1} - 2\phi_{i,j}}{h^2} \quad (3-36)$$

$$\phi_{xy} = \frac{\phi_{i+1,j+1} - \phi_{i-1,j+1} - \phi_{i+1,j-1} + \phi_{i-1,j-1}}{h^2} \quad (3-37)$$

经过有限差分法得到水平集演化的偏微分方程 3-30 将按照如下形式进行数值求解：

$$\begin{aligned} \frac{\phi_{i,j}^{n+1} - \phi_{i,j}^n}{\Delta t} = & -\delta_\varepsilon(\phi_{i,j}^n) \left(\omega(\lambda_1 e_1(\phi_{i,j}^n) - \lambda_2 e_2(\phi_{i,j}^n)) - |f_1(\phi_{i,j}^n) - f_2(\phi_{i,j}^n)| \right) + \mu \delta_\varepsilon(\phi_{i,j}^n) k \\ & + \nu (\phi_{i+1,j}^n + \phi_{i-1,j}^n + \phi_{i,j+1}^n + \phi_{i,j-1}^n - 4\phi_{i,j}^n - k) \end{aligned} \quad (3-38)$$

其中水平集的曲率 k 可通过中心二阶差分求解得到：

$$k = \text{div} \left(\frac{\nabla \phi}{|\nabla \phi|} \right) = \frac{\phi_{xx} \phi_y^2 - 2\phi_{xy} \phi_x \phi_y + \phi_{yy} \phi_x^2}{(\phi_x^2 + \phi_y^2)^{3/2}} \quad (3-39)$$

算法步骤:

步骤 1: 设定参数的值 μ , ν , σ ;

步骤 2: 给定初始轮廓, 并对水平集函数 ϕ_0 进行初始化;

步骤 3: 根据式 3-22 和 3-23 分别计算 m_1 和 m_2 ;

步骤 4: 根据式 3-38 更新水平集函数 ϕ_n ;

步骤 5: 判断是否满足收敛标准, 否则返回步骤 3。

收敛标准: $|\phi_{n+1} - \phi_n| \leq T$, 其中 ϕ_n 为第 n 次迭代的零水平集, ϕ_{n+1} 是下一次迭代的零水平集, T 为常数, 在本文中取 $T = 0.01$ 。

3.5 实验结果与分析

本文改进的模型能够有效解决局部模型容易陷入局部极小值的缺陷, 提高对灰度不均匀图像分割的准确性和鲁棒性。与此同时, 分割性能的提升使得本文模型的应用范围更广, 对实际应用中的复杂图像如医学图像, 自然场景图像也能够进行有效分割。本节将通过多组对比实验来对本文模型分割的有效性进行充分验证。(1) 对灰度不均匀图像的分割; (2) 对医学图像的分割; (3) 对自然图像的分割; (4) 分割精确度对比。


此外, 本文的实验平台是 MATLAB R2016a, Microsoft windows 10 64 位操作系统, CPU i7 4790, 内存 8GB。实验参数如无特殊说明选择如下: $\sigma=3$, $\lambda_1=\lambda_2=1$, $\nu=0.003 \times 255 \times 255$, 时间步长为 0.02。


3.5.1 对灰度不均匀图像的分割

如图 3-3 为 LIF 模型、RSF 模型、LLIF 模型和本文模型对四幅灰度不均匀图像进行分割的对比实验。其中, 图像 (1) 是一幅含噪声的合成图像, 大小为 152×152 像素, 图像 (2) 是一幅边缘模糊的汽车红外图像, 大小为 118×93 像素, 图像 (3) 是一幅光照很不均匀且含噪声的合成图像, 大小为 79×75 像素, 图像 (4) 为一幅目标和背景灰度不均匀的人工合成图像, 大小为 97×103 像素。第一行为原始图像与初始轮廓的设置, 第二行为 RSF 模型对四幅图像的分割结果, 第三行为 LIF 模型的分割结果, 第四行为 LLIF 模型的分割结果, 最后一行展示了本文模型分割结果。

本组实验的参数设置: 图像 (1) 中, RSF 模型: $\nu = 0.007 * 255 * 255$, $\sigma=8$; 对于

图像（2）：RSF 模型： $\nu=0.008*255*255$ ；RLSF 模型： $\sigma=8$ ， $\nu=0.08*255*255$ 。





本文模型分割结果

图 3-3 不同模型对灰度不均匀图像的分割结果对比


Fig. 3-3 Segmentation results of different models on images with intensity in


由分割结果可见，本文模型在分割这四幅灰度不均匀图像时都能够取得准确的分割结果。对于图像（1），虽然目标和背景都存在严重的噪声污染，但是当演化曲线位于目标内部或背景区域时，局部小邻域内的目标和背景拟合项即 m_1 和 m_2 的差异很小，曲线将不会停止在这些区域，在类间项的作用下继续向目标边界演化，当曲线演化至目标边界时，由图可见目标和背景的灰度差异很大，此时 m_1 和 m_2 的差异很大，演化曲线将准确的停止在目标边界。而 LIF 模型和 LBF 模型没有类间项的约束作用，受噪声干扰较大，曲线会停留目标内部或者背景区域这些错误的位置。LLIF 模型加入了图像的方差信息，虽然对噪声有一定的抑制作用，但并不是十分理想。在图像（2）中，RSF 和 LIF 模型有部分曲线停留在了车子内部和背景处。在图像（3）中，其他模型受照度不均匀影响较大，在背景和内部均出现了不停程度的误分割，而本文模型很好的克服了这一干扰。同理，在图像（4）中，其他三种模型都受到了目标内部以及背景处灰度不均匀的影响出现了误分割，本文模型获得了正确的分割结果。

3.5.2 对医学图像的分割

如图 3-4 为 RSF 模型、LIF 模型、LLIF 模型和本文模型对四幅医学图像进行分割的对比实验。医学图像由于采集设备的限制和人体组织的特性，存在很严重的噪声和模糊问题，十分不利于开展图像分割工作。第一行为四幅大小为 136×132 像素的人体不同组织的超声图像以及统一设置的初始轮廓，LBF 模型、LIF 模型、LLIF 模型和本文模型的分割结果分别如第二、三、四和最后一行所示。由于这组图像受噪声干扰较严重，适宜选取较大的高斯窗口和较大的长度约束项来获取相对光滑干净的分割曲线，本组选取 $\sigma = 8$ ， $\nu = 0.008 * 255 * 255$ 。本文模型对四幅超声图像都能取得准确的分割结果，虽然图像存在大量的噪点，但是在目标内部或背景区域，本文模型可以利用类间项有效判断出邻域内目标和背景的拟合平均值差异很小，没有达到边界点的条件，于是不会停留在

目标内部或背景区域，曲线将在类间项的作用下继续演化直到到达目标边界。而目标和背景的灰度差异还是很大的，那么类间项计算得到的邻域内目标和背景的拟合平均值差异会很大，达到边界条件，曲线就停止在边界处，最终生成了干净光滑准确的分割曲线。RSF 模型，LIF 模型受噪声干扰严重，例如在图像（1）和图像（3）中产生大量由伪边界点形成的不成线的分割结果，LLIF 模型相对来说抑制了部分噪点，但是没有类间项的限制仍旧会陷入局部极小值，无法取得满意的分割结果。





本文模型分割结果

图 3-4 不同模型对医学图像的分割

Fig. 3-4 Segmentation results of different models on medical images

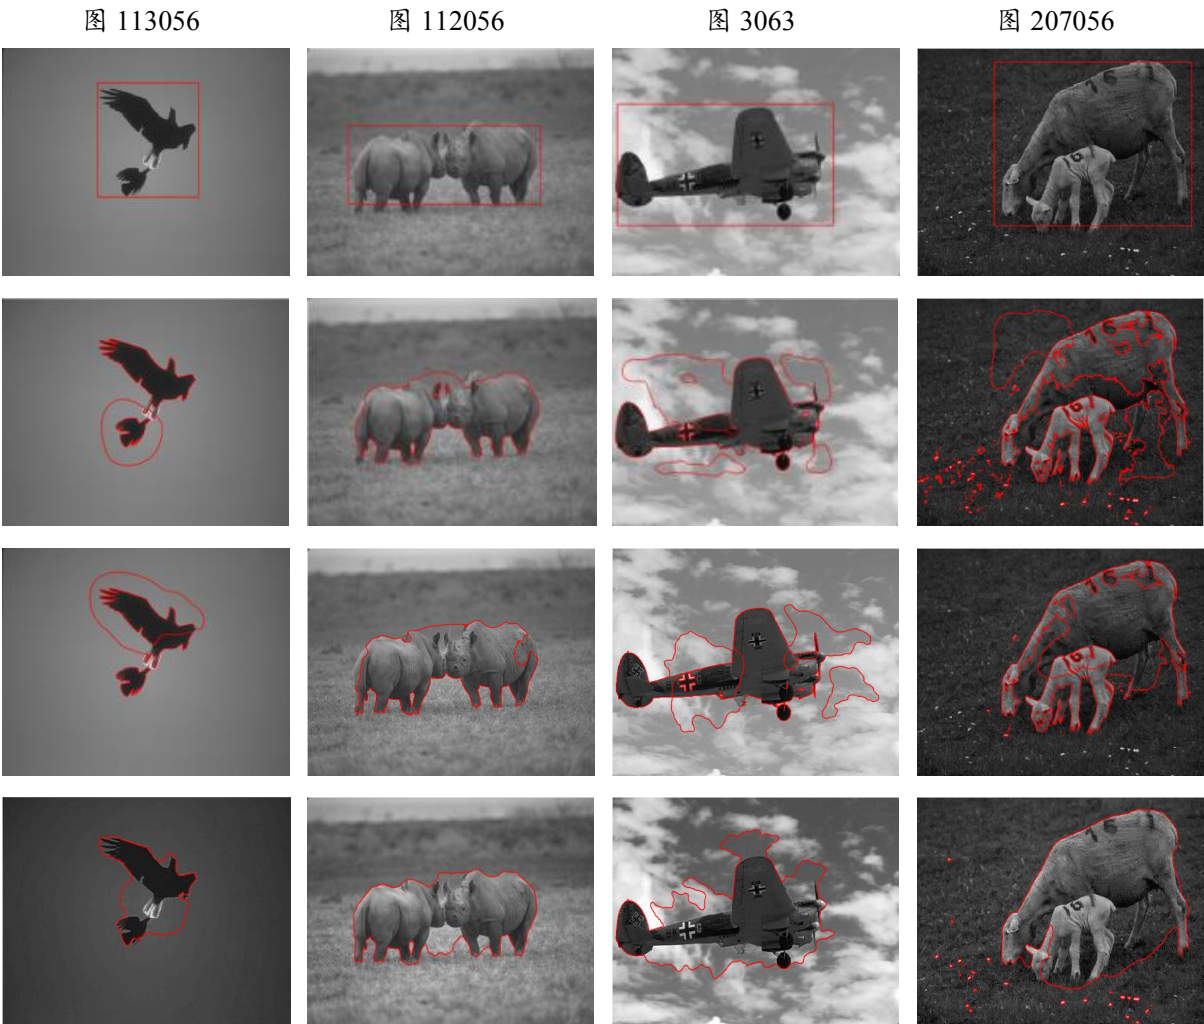
3.5.3 对场景复杂的自然图像的分割

为了进一步说明本文模型分割能力以及实际利用价值，本文选取了四幅来自 Berkeley 图像数据集（BSDS）中的自然图像进行了对比实验。这四幅图像的大小均为 481×321 像素，在数据集中的编号分别为：135069，112056，3063，207056。如图 3-5 为四种模型的分割结果。图 135069 中的老鹰所处的天空受光线影响导致背景不均匀，RSF 模型、LIF 模型和 LLIF 模型的分割结果均落入了背景中，LIF 模型有部分分割结果落入目标内部，本文模型完成了正确的分割。图 112056 中犀牛和草地均存在一定程度的灰度不均，RSF 模型，LIF 模型的分割结果有部分停留了背景处和目标内部，LLIF 模型相对较好，但仍有部分结果处在背景中没有演化到目标边界，本文模型获取到了准确的分割结果。图像 3063 中的目标飞机本身的结果比较复杂，且所处的背景由于云层的存在而对分割带来了较大的干扰，RSF 模型，LIF 模型，LLIF 模型受背景干扰影响严重，在背景区域存在大面积的误分割，且 RSF 模型和 LIF 模型由于目标结构的复杂，在目标内部也存在严重的误分割情况，本文模型在类间项的作用下，有效辨别背景和目标，驱动演化曲线准确的停靠在目标的边缘。图 207056 是一幅多目标的图像，目标所处的草地灰度不均匀程度较高，RSF 模型和 LIF 模型在目标内部出现了过多的误分割，LLIF 模型由于添加了方差信息，这一现象得到了一些改善，其次在背景区域，三种模型也存在不同程度的不成线的伪边界点，本文模型能够很好的克服这些问题，完成理想的分割。

通过对四副自然图像的分割进一步说明了在分割场景复杂的灰度不均匀自然图像时，RSF 模型和 LIF 模型在分割过程中仅依靠局部灰度信息，在分割复杂自然图像时十分困难，LLIF 模型进一步加入了图像的方差信息，能获得比 RSF 模型和 LIF 模型更好的结

果，但仍然存在误分割的区域。前面三种模型均只考虑了拟合图像与目标图像的差异，而本文模型相不仅考虑了拟合图像与原始图像的差异，同时考虑了拟合图像中邻域内目标和背景的差异，有效利用类间方差项，来进一步排除造成局部极小值的伪边界点，避免了演化曲线停留在目标内部或背景处等错误的区域，从而获得正确的分割结果。

参数设置：RLSF 模型四副图像选取： $\nu=0.08*255*255$ 。对于图 113056，RSF 模型： $\nu=0.05*255*255$ ， $\sigma=8$ 。对于图像 112056，RSF 模型： $\nu=0.02*255*255$ ， $\sigma=8$ 。对于图像 3063，RSF 模型： $\sigma=8$ 。






图 3-5 不同模型对自然图像的分割

Fig. 3-5 Segmentation results of different models on natural images

3.5.4 分割精度

为了进一步直观地说明本文模型与其它模型相比，本文模型的分割精度更高，本节采用两个相似性度量来对各模型分割得到的结果进行定量比较，分别为 DSC（dice similarity coefficient）和 Jaccard（jaccard similarity）^[52]，其定义分别如下：

$$DSC = \frac{2 \cdot N(S_g \cap S_m)}{N(S_g) + N(S_m)} \quad (3-39)$$

$$JS = \frac{N(S_g \cap S_m)}{N(S_g \cup S_m)} \quad (3-40)$$

其中， S_g 表示各模型的分割结果， S_m 表示标准分割结果，Berkeley 图像数据集 BSDS 已提供了标准分割结果，本节将各模型采集到的分割结果与数据库中提供的标准结果进行对比。 $N(\cdot)$ 表示分割区域所包含的像素点数。DSC 和 JS 的评价指标为模型的分割结果与数值 1 的接近程度，DSC 和 JS 的数值越接近于 1，说明模型的分割结果越接近于数据库提供的标准分割，那么该模型的分割就越准确。表 3-1 为 RSF 模型，LIF 模型，LLIF 模型，本文模型对图 3-5 中四幅自然图像进行分割的 DSC 和 JS 值的对比

表 3-1 图 3-5 中 RSF 模型、LIF 模型、LLIF 模型和本文模型分割结果的 DSC、JS 值

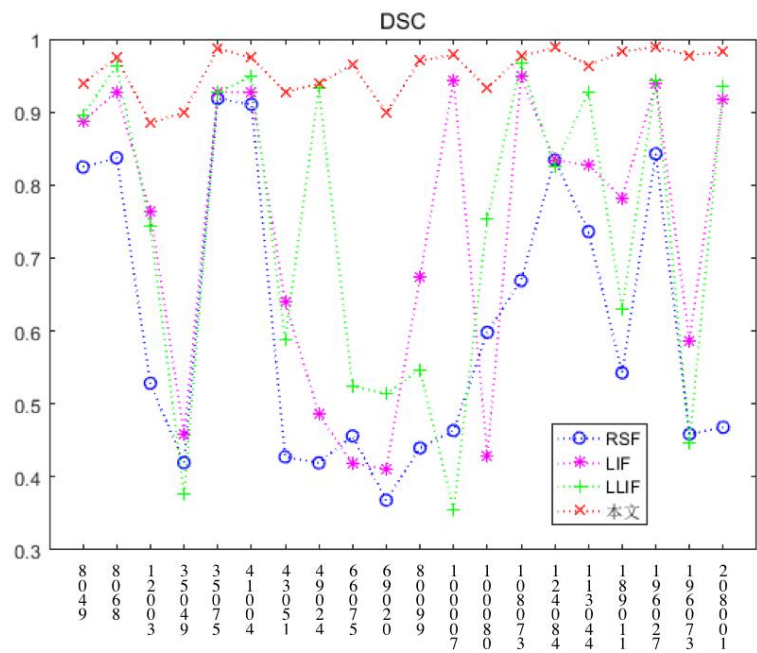
Table 3-1 DSC and JS values for the segmentation results using the RSF model, LIFmodel, LLIFmodel and the proposed model in Fig.3-5

图像	RSF		LIF		LLIF		本文模型	
	DSC	JS	DSC	JS	DSC	JS	DSC	JS
135069	0.8374	0.7849	0.7592	0.6957	0.8165	0.7937	0.9875	0.9573


112056	0.9343	0.8768	0.9342	0.8753	0.9474	0.8996	0.9781	0.9472
3063	0.6990	0.5027	0.7387	0.6721	0.7728	0.6984	0.9766	0.9421
207056	0.4275	0.2673	0.6391	0.4747	0.7865	0.7093	0.9639	0.9324

了
使

本文模型的结果更具有说服力，本文选取了 Berkeley 图像数据集 BSDS 中的 20 幅自然图像进行分割，并计算了四种模型分割结果的 DSC 和 JS 值列入图 3-6 中，同时计算了 DSC 值和 JS 值的平均值和标准差如表 3-2 所示。



(a) 不同模型的 DSC 值对比



(b) 不同模型的 JS 值对比

图 3-6 不同模型对 BSDS 数据集中 20 幅图像进行分割的 DSC 值和 JS 值

Fig.3-6 The DSC values and JS values of 20 images in BSDS data set by different models

由图 3-6 可见，与 RSF 模型、LIF 模型、LLIF 模型相比，本文模型的 DSC 值和 JS 值的结果更接近于 1，且在表 3-2 中，本文模型的 DSC 值平均值最高，说明本文模型的分割准确率更高。由表 3-2 中不同模型的 DSC 值和 JS 值可见，本文模型的标准差最小，说明本文模型在分割不同的图片时表现得更加稳定。

表 5-1 不同模型对 BSDS 数据集中 20 幅图像进行分割的 DSC 值和 JS 值的平均值和标准差

Table 1 The mean and standard deviation of DSC values and JS values of 20 images in BSDS data set by

	different models			
	DSC 值		JS 值	
	平均值	标准差	平均值	标准差
RSF 模型	0.5854	0.2083	0.4748	0.2591
LIF 模型	0.6840	0.2326	0.5982	0.2747
LLIF 模型	0.6977	0.2347	0.6178	0.2743

本文模型	0.9539	0.0342	0.9346	0.0336
------	--------	--------	--------	--------

3.6 本章小结

本章深入研究并剖析了局部模型在分割灰度不均匀图像时容易陷入局部极小值的问题，并针对这一问题提出了一个能够有效解决局部极小值问题的模型。新的模型将最大类间方差思想引入局部分割模型，在局部模型的基础上增加了类间方差能量项，通过最大化演化曲线上所有点的邻域内目标和背景的差异来剔除使演化曲线陷入局部极小值的伪边界点，驱使演化曲线最终停留在正确的目标边界。由于以往提出的局部模型仅考虑拟合图像与原始图像的差值，对边界点的把握不是很准确，容易陷入局部极小值，而本文提出的模型不仅考虑拟合图像与原始图像的差值，同时考虑了拟合图像邻域内目标和背景的差异。为了证明本文模型对不同图像分割的有效性，本章进行了一系列对此实验，结果表明改进的模型可以有效地解决局部模型因陷入局部极小值而导致的误分割问题，提高对灰度不均匀以及复杂图像的分割准确度。

第四章 引入图像熵的权重自适应活动轮廓模型

本章提出了一个融合图像全局信息和局部信息的混合模型，并针对调节两项权重参数的选择提供了一个自动化的解决方案。首先将改进的局部模型 VLIF 与全局模型 CV 结合，在权重函数的自适应指导下构建了一个更加稳健的模型，利用图像局部熵建立了精确可靠的衡量图像灰度信息的指标，通过实时获取图像分割过程中的灰度分布情况自适应的指导模型中不同功能能量项配比，实现全自动化分割。相比传统基于反复试验的固定参数线性调整模式，本文选择了一种更加量化和合理的方式实现了全局项与局部项的动态非线性调整，完成了对多种类型图像的快速准确分割。实验表明本文模型对于不同类型的灰度不均匀和噪声图像，能够完成快速准确的分割，且稳定性较高，对初始轮廓的位置也不敏感。

4.1 研究背景

局部模型能够在分割灰度不均匀图像时取得较好的分割结果，但是其仅依靠图像的局部信息，对初始轮廓的敏感性较强。全局模型虽然不能很好的处理灰度不均匀图像，但是对初始轮廓的敏感性较低，且演化曲线收敛速度快。此外，由于图像在不同区域的灰度不均匀程度是不同的。在图像灰度分布相对均匀的区域，适宜采用收敛速度快的全局模型进行分割，在图像灰度分布不均匀的区域，适宜采用局部模型来对图像进行精确的分割。

于是，为了根据图像不同区域的灰度分布情况选择合适的数据项来引导曲线演化，并结合全局模型和局部模型各自的优点进行优势互补，大量的融合图像局部信息和全局信息的模型被提出^[53-55]，如 Wang^[53]等人提出的融合图像全局信息和局部信息的 LGIF 模型，通过全面的考虑图像的灰度信息获得更优的分割结果。然而在这个过程中需要选择一个合理的权重参数来分配局部项和全局项的占比，LGIF 不能自动选择权值参数，在实现时，通常都是人为设定的固定参数，目前所提出来的其他混合模型也存在同样的情况，通常是在演化初期设定一个固定的权重参数，进行全局项和局部项的线性调控。然而这一参数的选择往往需要通过多次反复试验来确定，在选取时耗费大量的时间和精力调整，最终选取的参数是基于反复试验和经验的，没有量化的选取标准。在曲线演化过程中，也不能根据图像的灰度情况实时的调整参数，而权值参数的选择会直接影响演化曲线的分割速度和准确率，不当的参数选取会造成演化速率的大大减小，且分割结果

不理想。此外不同的图像所需要的参数不固定，这更加导致权重参数的选择工作繁复复杂。因此，我们迫切需要一种对图像高效、准确而又不需要人工过多参与、消耗人力的自动分割的方法。本文正是基于此初衷，找到一种更加精确可靠的衡量图像灰度信息的指标，以此为基准建立反映图像信息的特征函数，利用该特征函数自适应的指导模型中不同功能能量项配比，实现全自动化分割，从而提升传统活动轮廓模型的运算速度和无监督自适应等性能，满足图像处理相关需求。

4.2 相关理论

4.2.1 图像熵理论

信息熵^[56]的理论自 1948 年被 Shannon 提出来以后，被广泛应用于图像处理领域。图像熵可以表示图像各级灰度的分布特征，描述图像的灰度均匀程度^[57]。

在图像分割中的任意时刻，演化曲线将图像分割为内外两部分区域，即 $inside(C)$ 和 $outside(C)$ 两部分。本文算法在每次迭代中获取演化曲线的位置，并计算曲线内部区域的图像局部熵 E_{in} 。

$$E^{in} = -\sum_{i=1}^N p_i \log_2 p_i \quad (i \in inside(C)) \quad (4-1)$$

其中， N 表示图像的灰度级， p_i 表示第 i 级灰度出现的概率^[58]，根据熵函数的极值性，当系统各元素概率均等时，熵函数取得最大值^[59]。由于分割曲线内部图像灰度的取值范围为 $[0, 255]$ ，当每一级灰度出现的概率相等时，熵函数取得最大值，由此计算得出图像局部熵函数的值域为 $[0, 8]$ 。根据 Shannon 信息熵理论，当系统中事件的发生概率均等时，熵值最大。如果将这一理论推广到图像领域，那么当图像灰度均匀分布时，熵值较大，反之熵值较小^[60]。因此图像熵可以有效地衡量图像的灰度分布情况，适合作为权重参数来调节全局项与局部项的比重。

4.2.2 局部图像熵

对于一幅给定的图像 $I: \Omega \rightarrow R^2$ ，以第三章中局部模型的邻域思想为基础，对图像中任意一个像素点 x 及其半径为 r 的邻域 $\Omega_x \in \Omega$ ，根据图像熵的定义，计算像素点 x 邻域内图像熵的表达式如下：

$$E(x, \Omega_x) = -\frac{1}{\log|\Omega_x|} \int_{\Omega_x} P(y, \Omega_x) \log P(y, \Omega_x) dy \quad (4-2)$$

其中， y 为邻域内的像素值， $P(y, \Omega_x)$ 为邻域内像素灰度级分布的概率函数。

$$P(y, \Omega_x) = I(y) \int_{\Omega_x} I(z) dz, y \in \Omega_x \quad (4-3)$$

图像局部熵是邻域内所有像素共同作用的结果，可以有效反映局部邻域内灰度值的变化以及离散程度，同时图像熵的计算具有抗噪声干扰和抗几何形变的能力^[61]，因此本文将利用图像局部熵这一数学量来构建指导模型数据项配比的特征函数。

4.2.3 CV 模型

为简化 Mumford-Shah^[27]模型，Chan 和 Vese 于 2001 年提出了基于图像全局信息的 C-V 模型^[28]，其核心思想是把图像中的目标和背景考虑成两个简单的两类问题，利用简单的二聚类思想控制曲线朝目标边界演化，从而划分图像的目标和背景^[63]。

对于要分割的图像 I ，图像域为 Ω ，假定图像是由灰度均匀分布的目标和背景两部分组成，得到曲线 C 演化的能量泛函定义如下：

$$E^{CV}(C, c_1, c_2) = \lambda_1 \int_{inside(C)} |I(x) - c_1|^2 dx + \lambda_2 \int_{outside(C)} |I(x) - c_2|^2 dx \quad (4-4)$$

其中， λ_1 和 λ_2 为非负常量，一般取 $\lambda_1 = \lambda_2 = 1$ 。 C 表示图像域内的闭合演化曲线。在任意时刻，图像 I 被演化曲线 C 划分为目标和背景两个区域，即 $inside(C)$ 和 $outside(C)$ 两部分， c_1 表示目标区域的平均灰度值， c_2 表示背景区域的平均灰度值。

C-V 模型可以得到全局最优分割，避免陷入局部极小值，且演化时曲线收敛速度快，对初始轮廓的位置也不敏感。但由于其没有考虑到图像局部灰度特征的变化，在分割噪声图像和灰度不均匀图像时表现较差。

4.3 基于图像熵的权重自动调节活动轮廓模型

本文利用改进后的 VLIF 模型构建新模型的局部能量项，利用 C-V 模型构建新模型的全局能量项，两个数据能量项在权重函数的调节下共同驱动曲线向目标边缘演化。

全局项和局部项对演化曲线的调节机制是：在图像灰度分布不均匀的区域以及靠近目标边缘的区域，由局部项主导曲线进行演化。这是因为通常情况下这些区域灰度信息比较复杂且灰度值变化较大，局部项采用邻域思想能够精确地捕捉邻域内灰度信息的细微变化，使分割曲线准确地停靠在目标边缘。在图像灰度分布较均匀的区域，由全局项

主导曲线进行快速演化，因为图像灰度分布均匀的区域一般为背景或者目标内部，此时使曲线快速演化可以尽快到达目标边缘。

由此可见，在分割一幅图像时，对于不同的区域，全局项和局部项所占的比重都应该是不相同的，这一过程需要权重参数根据不同区域的灰色分布情况进行一个非线性的调控。若权重参数偏向全局项，会导致局部项所占的比重不够大，对灰度不均匀区域的信息变化掌握不充分从而无法进行更准确的分割，且对初始轮廓比较敏感；若权重参数偏向局部项，会导致演化曲线过于缓慢，增加不必要的计算开销。因此选择适当的权重参数对分割结果和计算效率十分重要。

本文基于图像熵可以有效反应灰度分布信息的思想，将利用图像局部熵来构建反映邻域灰度变化的特征函数作为权重函数，通过动态调节全局数据项与局部数据项的配比来指导曲线演化。这样，权重函数可以实时地利用图像熵的变化来获取图像不同区域灰度的分布情况，从而自适应地对全局项和局部项的占比进行非线性的调控。当图像灰度分布较均匀时，图像熵值较大，此时由全局项主导轮廓曲线演化；当图像灰度分布不均匀时，图像熵值较小，由局部数据能量拟合项主导轮廓曲线的演化，能量泛函定义如下：

$$E(C) = (1 - \omega)E^{VLF} + \omega E^{CV} \quad (4-5)$$

其中， $\omega(0 \leq \omega \leq 1)$ 为权重参数，用来控制局部能量项和全局能量项的占比，它的值有图像局部邻域内熵的值来确定，即：

$$\omega = a \cdot E(x, \Omega_x) \quad (4-6)$$

由 4.2.2 小节知，

$$E(x, \Omega_x) = -\frac{1}{\log|\Omega_x|} \int_{\Omega_x} P(y, \Omega_x) \log P(y, \Omega_x) dy \quad (4-7)$$

其中， a 为标准化因子，其作用是使得权重参数的值在 $[0, 1]$ 范围内。由 4.2.1 节可知，由于图像灰度的取值范围为 $[0, 255]$ ，所以图像熵的最大值为 8，即 $0 \leq E(x, \Omega_x) \leq 8$ ，因此本文令 $a = \frac{1}{8}$ ，使得 $0 \leq \frac{1}{8} E(x, \Omega_x) \leq 1$ ，符合权重的取值范围。

4.4 能量泛函求解

将 4-5 中的演化曲线 C 替换为零水平集函数 φ ，得到关于水平集函数的能量泛函：

$$\begin{aligned}
 E(\varphi) &= (1-\omega)E^{VLIF} + \omega E^{CV} \\
 &= (1-\omega) \left\{ \frac{1}{2} \int_{\Omega} |I(x) - I^{LFI}(x)|^2 dx - \int_{\Omega} H_{\varepsilon}(\varphi(x))(1 - H_{\varepsilon}(\varphi(x))) |m_1 - m_2|^2 dx \right\} \\
 &\quad + \omega \left\{ \lambda_1 \int_{inside(C)} |I(x) - c_1|^2 dx + \lambda_2 \int_{outside(C)} |I(x) - c_2|^2 dx \right\}
 \end{aligned} \tag{4-8}$$

为防止水平集函数偏离符号距离函数，加入无需初始化的距离惩罚项来保证曲线的稳定演化：

$$P(\varphi) = \int_{\Omega} \frac{1}{2} (|\nabla \varphi(x)| - 1)^2 dx \tag{4-9}$$

为了使曲线在演化过程中尽可能短而平滑，加入长度惩罚项^[63]：

$$L(\varphi) = \int_{\Omega} \delta_{\varepsilon}(\varphi) |\nabla \varphi| dx \tag{4-10}$$

于是得到本文模型的最终能量泛函为：

$$E(\varphi) = (1-\omega)E^{VLIF} + \omega E^{CV} + \nu L(\varphi) + \mu P(\varphi) \tag{4-11}$$

根据变分法和标准梯度下降流^[49]，得到关于水平集演化的表达式如下：

$$\begin{aligned}
 \frac{\partial \varphi}{\partial t} &= \delta_{\varepsilon}(\varphi)(F^{VLIF} + F^{CV}) + \nu \delta_{\varepsilon}(\varphi) \operatorname{div} \left(\frac{\nabla \varphi}{|\nabla \varphi|} \right) + \\
 &\quad \mu \left(\nabla^2 \varphi - \operatorname{div} \left(\frac{\nabla \varphi}{|\nabla \varphi|} \right) \right)
 \end{aligned} \tag{4-12}$$

其中， F^{VLIF} 和 F^{CV} 分别为局部拟合力和全局拟合力：

$$F^{VLIF} = (1-\omega) \left((I - I^{LFI})(m_1 - m_2) - \omega_1 \omega_2 |m_1 - m_2|^2 \right) \tag{4-13}$$

$$F^{CV} = \omega \left[-\lambda_1 (I - c_1)^2 + \lambda_2 (I - c_2)^2 \right] \tag{4-14}$$

$H_{\varepsilon}(\varphi)$ 和 $\delta_{\varepsilon}(\varphi)$ 分别为 Heaviside 函数和它的一阶导 Dirac 函数：

$$H_{\varepsilon}(x) = \frac{1}{2} \left[1 + \frac{2}{\pi} \arctan\left(\frac{x}{\varepsilon}\right) \right] \tag{4-15}$$

$$\delta_{\varepsilon}(x) = H'_{\varepsilon}(x) = \frac{1}{\pi} \frac{\varepsilon}{\varepsilon^2 + x^2} \tag{4-16}$$

在全局项中， $c_1(\varphi)$ 和 $c_2(\varphi)$ 的值分别为：

$$c_1(\varphi) = \frac{\int_{\Omega} I(x) H_{\varepsilon}(\varphi(x)) dx}{\int_{\Omega} H_{\varepsilon}(\varphi(x)) dx} \quad (4-17)$$

$$c_2(\varphi) = \frac{\int_{\Omega} I(x) (1 - H_{\varepsilon}(\varphi(x))) dx}{\int_{\Omega} (1 - H_{\varepsilon}(\varphi(x))) dx} \quad (4-18)$$

由知，在局部中， $m_1(x)$ 和 $m_2(x)$ 的值分别为：

$$m_1(x) = \frac{K_{\sigma}(x) * [H_{\varepsilon}(\varphi(x)) I(x)]}{K_{\sigma}(x) * H_{\varepsilon}(\varphi(x))} \quad (4-19)$$

$$m_2(x) = \frac{K_{\sigma}(x) * [(1 - H_{\varepsilon}(\varphi(x))) I(x)]}{K_{\sigma}(x) * (1 - H_{\varepsilon}(\varphi(x)))} \quad (4-20)$$

算法步骤：

步骤 1：设定参数的值 μ , ν , σ ；

步骤 2：给定初始轮廓，并对水平集函数 φ_0 进行初始化；

步骤 3：根据式 4-19 和 4-20 分别计算 $m_1(x)$ 和 $m_2(x)$ ，根据式 4-17 和 4-18 分别计算 $c_1(\varphi)$ 和 $c_2(\varphi)$ ；根据式 4-7 计算图像熵 $E(x, \Omega_x)$ 得到权重参数 ω ，

步骤 4：根据式 4-12 更新水平集函数 φ_n ；

步骤 5：判断是否满足收敛标准，否则返回步骤 3。

收敛标准： $|\varphi_{n+1} - \varphi_n| \leq T$ ，其中 φ_n 为第 n 次迭代的零水平集， φ_{n+1} 是下一次迭代的零水平集， T 为常数，在本文中取 $T = 0.01$ 。

4.5 实验结果与分析

本章设置的实验将通过以下几个方面来验证本文模型的有效性：（1）对初始轮廓的敏感性；（2）权重参数自动选择的有效性；（3）对自然图像的分割；（4）对医学图像的分割；（5）分割效率对比。

本章的实验平台是 MATLAB R2016a，Microsoft windows 10 64 位操作系统。

本章实验的默认参数选择如下：时间步长 $\Delta t = 0.1$ ，空间步长 $h=1$ ，Heaviside 函数和 Dirac 函数中的参数 $\varepsilon=1$ ，长度惩罚系数 $\nu = 0.003 \times 255 \times 255$ ，高斯窗口大小 $\sigma = 3$ 。在以下的实验中，各模型部分参数的选择会根据具体图片进行调整，具体的参数选择将在实验后面的说明中指出。

4.5.1 对初始轮廓的敏感度实验

本文设置了两组对比实验来验证本文模型对初始轮廓的鲁棒性，分别如图 4-2 和图 4-3 所示。图 4-2 使用一幅大小为 434×329 的灰度分布不均匀人工合成图像来测试不同模型在不同位置和大小初始轮廓曲线下分割结果。第一列为原始图像与初始轮廓设置，LIF 模型、LGIF 模型和本文模型的分割结果分别在第二列，第三列和最后一列展示。本组实验中 LIF 模型的长度项参数的设置为： $\nu = 0.007 * 255 * 255$ ，LGIF 模型权重参数的设置为： $\omega = 0.001$ 。本文模型由权重函数自动赋值，无需手动调节权重参数。分割结果表明：LIF 模型仅依赖图像的局部信息，在没有全局信息的直到下，对初始轮廓十分敏感，在给出的这几个初始轮廓下均不能完成正确的分割，LGIF 模型虽然融合了全局信息，但是对权重参数的选择敏感，只有在特定的初始轮廓和特定的权重参数下，即最后一种情况下才能完成正确的分割，而本文模型不受初始轮廓曲线大小以及位置的限制，无论在下面三种中的哪一种情况下，均可完成正确的图像分割。由此说明本文模型有效利用权重函数的自动调节机制，对全局项与局部项选择了合适的配比，完成了准确分割。




图 4-2 不同初始轮廓位置下的分割

Fig.4-2 Results of different model with different initial contours on a synthetic images.

为了更充分的验证本文模型对初始轮廓不敏感，第二组对比实验增加了分割难度，选取了两幅灰度不均匀程度更高且被噪声污染的合成图片，同时在设定初始轮廓时选取了不同的位置（图像中心，背景处，目标内部）和不同的大小如图 4-3 所示。实验结果表明本文模型仍旧不受初始轮廓位置以及大小的影响，在权重函数的指导下自动调整全局项与局部项的占比，根据图像不同区域的灰度特性选取了合适的能量项配比，从而取得正确的分割结果。




图 4-3 本文模型对两幅合成图像在不同初始轮廓曲线下的分割。其中蓝色矩形框为初始轮廓曲线，红色曲线为最终分割结果。

Fig.4-3 Results of our model with different initial contours on two synthetic images.

The initial contours and the final contours are plotted as blue rectangles and red contours.

4.5.2 权重函数自动调节的有效性

为了进一步说明权重参数的自动调节对分割结果的重要性，本组实验展示了本文模型在不同的权重参数指导下对一幅存在灰度不均匀的飞机场遥感图像进行分割的结果。图像 4-4(1)为原始图像与随机选取的初始轮廓；图像 4-4(2)-(3)为本文模型在不同的固定

权重参数对遥感图像的分割结果，图 4-4(4)为本文模型在权重函数动态调节下的分割结果。由实验结果可知在固定参数的线性调整下，本文模型无法取得准确的分割结果，而在由图像局部熵构造的权重函数下，通过分析图像不同区域的灰度离散情况动态调整适合不同区域的权重，这种自动化的非线性调整机制能够更好的分配全局项和局部项占比，有利于模型获得准确的分割结果。




图 4-4 本文模型在不同权重下对遥感图像的分割

Fig.4-4 Segmentation results of different weight parameters for an remote sensing image

4.5.3 对自然图像的分割

为了进一步测试本文模型的分割性能和实践价值，本组实验选取了分割难度较大的自然图像进行了实验，测试图像均来自 Berkeley 图像数据集 BSDS。如图 4-5 展示了不同模型对四幅自然图像进行分割的对比结果。其中，第一行为原始图像与初始轮廓，这四幅图像的大小均为 481×321 像素，在 BSDS 数据集中的编号分别为：3096，61060，113044，35010。第二行、第三行和最后一行分别为为 LIF 模型、LGIF 模型和本文模型的分割结果。




图 4-5 不同模型对自然图像的分割

Fig.4-5 Segmentation results of different models on natural images

参数选择：LIF 模型：在图像 3096 的分割中， $\sigma=8$ ，在图像 61060 的分割中， $\nu=0.01 \times 255 \times 255$ ，在图像 113044 中的分割中， $\sigma=8$ ；LGIF 模型：在图像 3096 的分割中， $\sigma=5$ ， $\omega=0.5$ ，在图像 61060 的分割中， $\nu=0.01 \times 255 \times 255$ ， $\omega=0.01$ ，在图像 113044

中的分割中, $\nu=0.01 \times 255 \times 255$, $\omega=0.05$; 在图像 35010 的分割中, $\nu=0.08 \times 255 \times 255$, $\omega=0.03$ 。其他未特别说明的参数均为默认参数。


图 3096 为处于背景不均匀环境中的飞机图像, LIF 模型和 LGIF 模型在背景区域产生了误分割。图 61060 滑雪者本身的灰度比较复杂, 并且所处的雪地灰度分布也十分不均匀, 加大了分割的难度, LIF 模型和 LGIF 模型无法准确分割目标人物且在背景区域产生了大量的误分割。图 113044 中的目标马匹受光线反射影响灰度不均匀情况十分严重, 草地的也为分割过程带来了干扰, LIF 模型和 LGIF 模型几乎无法进行分割。图 35010 受蝴蝶自身花纹的影响和所处背景结构的复杂, LIF 模型和 LGIF 模型分割结果也是十分的不理想。本文模型对于这四幅场景复杂的灰度不均匀图像均能够准确的分割。

对三种模型的分割结果进行分析: LIF 模型仅利用图像的局部信息进行分割, 在分割场景复杂的自然图像时容易陷入局部极小值, 造成误分割; LGIF 模型虽然融合了图像的全局以及局部信息指导曲线演化, 但是对权重参数的选择十分敏感, 基于反复试验人为选取的参数难以匹配到最准确合适的值, 且固定的权重使得每个区域的能量项配比只能是一致的, 同样无法完成正确的分割; 本文模型利用局部熵建立了灰度分布特征函数, 以此来衡量图像每个局部区域的灰度均匀情况后, 然后根据各个区域的灰度分布特征动态的调整全局项与局部项的能量配比, 这种量化的动态调节模式有效帮助本文模型实现准确的分割。


4.5.4 医学图像分割

由于视网膜血管的结构复杂, 数量庞大且微小, 加之血管本身存在灰度不均匀性且血管边界的轮廓模糊, 导致传统模型无法对此类图像进行正确的分割^[64]。其中, 视盘内血管由于受灰度不均匀影响最大, 一直是视网膜血管分割中的难点。本文的视网膜图像数据自 STARE 国际数据库中的眼底视网膜血管彩色图像, 且选用噪声低和血管对比度高的绿色通道图像^[65,66]。本文对视网膜血管选取的分割区域均为 (343×343) 大小的图片。该组实验表明本文模型能够克服噪声和灰度不均匀的影响, 快速准确地完成对结构复杂的眼底视网膜血管的分割。图 4-6 为不同模型对视网膜血管的分割, 文本选取了视网膜血管图像中比较有代表性的区域, 标识在图 4-6 的(a), (b),(c)和(d)中, 其中(c)和(d)为视盘内血管。


LGIF 模型的权重参数选择如下： $\omega=0.06$ ， $\omega=0.5$ ， $\omega=0.0001$ ， $\omega=0.0005$ 。




原始图像及所选区域




初始轮廓曲线



LIF 模型分割结果



LGIF 模型分割结果



本文模型分割结果

图 4-6 不同模型对视网膜血管图像的分割

Fig. 4-6 Segmentation results on retinal blood vessel images by different models

图 4-6 的分割结果表明：对于图(e), LIF 模型出现了较大面积的多余曲线；LGIF 模型由于受右上角视盘干扰较大，造成分割失败。对于图(f), 本文模型相比 LIF 模型可以分割出更多的细微血管；LGIF 模型在右上角出现了误分割。对于图(g)和(h)，由于图视盘内血管受灰度不均匀干扰较大，LIF 模型和 LGIF 模型都不能完成正确分割。本文模型对于这类背景很不均匀的复杂图像，能有效利用类间差异项，减少误分割，同时能够实时获取当前的灰度信息，及时调整权重参数得到准确地分割结果。LIF 在分割血管时陷入局部极小值，造成血管分割不足和误分割；LGIF 因不能自适应地调节全局项和局部项的比重，造成血管分割结果不理想。

4.5.5 迭代时间与次数

为了直观的说明本文模型的分割效率更高，本节将上节中对自然图像和视网膜血管图像分割所需的迭代时间和次数列入表 4-1 和 4-2 中，进行比较说明。

表 4-1 为三种模型对 BSDS 数据集中四幅自然图像进行分割所需的迭代次数和运行时间。由表中的数据可知迭代次数和运算时间：LIF 模型>LGIF 模型>本文模型。LGIF 和本文模型均利用图像的全局项加快了曲线的演化，但是 LGIF 模型的权重参数在每一个区域都是固定的，而本文模型的权重在灰度均匀程度不一致的区域是不同的，在灰度均匀区域可以令全局项的占比较大，由此使曲线的演化速率大大加快，从而提高整体的分割效率。

表 4-1 图 4-5 中 LIF 模型、LGIF 模型和本文模型的迭代次数和运行时间

Table 4-1 The number of iterations and CPU times when using the LIF model, the LGIF model, the RLSE model and the proposed model of Fig 4-5

图像	LIF 模型		LGIF 模型		本文模型	
	迭代次数	分割时间/s	迭代次数	分割时间/s	迭代次数	分割时间/s
3096	150	112.2594	70	15.6747	30	13.2625
61060	100	44.3438	100	36.3045	30	13.6563
113044	100	57.0469	80	50.2685	50	21.4688
35010	140	62.9531	80	34.8533	40	18.1719

表 4-2 为三种不同模型分割视网血管图像所需的迭代次数以及运行时间。表中数据同样可得到迭代次数和运算时间：LIF 模型>LGIF 模型>本文模型。进一步说明本文模型通过权重函数的自适应非线性调节机制，为每个局部区域选择了最恰当的参数优化了算法，实现了局部项和全局项的比重均衡，进而提高分割效率。

表 4-2 图 4-6 中 LIF 模型、LGIF 模型和本文模型的迭代次数和运行时间

Table 4-1 The number of iterations and CPU times when using the LIF model, the LGIF model, the RLISM model and the proposed model of Fig 4-5

图像	LIF 模型		LGIF 模型		本文模型	
	迭代次数	分割时间/s	迭代次数	分割时间/s	迭代次数	分割时间/s
图像 e	300	11.3875	250	9.6327	180	7.1243
图像 f	750	25.2926	300	11.8362	210	8.2776
图像 g	550	17.3501	500	15.7093	350	10.2383
图像 h	540	16.2937	480	14.4516	350	10.8243

4.6 本章小结

为了全面的将图像的局部信息与全局信息整合利用，本章将第三章改进的模型作为局部项与全局模型 C-V 结合，利用图像的局部信息和全局信息共同驱动曲线演化，在改进的局部模型对图像进行准确分割的基础上结合全局模型的优势来进一步降低对初始轮廓的敏感度，提高演化曲线在灰度均匀区域的收敛速度。同时，本章利用图像局部熵建立了一个精确可靠的衡量图像灰度信息的指标，通过实时地计算图像熵值来判断图像的灰度分布情况，在每一次迭代中实时地更新符合当前灰度分布情况的权重参数，用一种非线性的调整模式自适应的指导模型中全局项与局部项的配比，实现全自动化分割。相比传统的固定权重参数线性调整模式，本文模型能够更好地平衡全局项与局部项的比重，提升活动轮廓模型的运算速度和无监督自适应等性能。最后，本文通过多组实验验证了本文模型相对于其他模型在处理多种类型的噪声和灰度不均匀图像时的优越性，不仅对轮廓曲线的初始化位置具有低敏感性，而且提高了分割精度，并使模型的运算时间、迭代次数得到明显的降低。

第五章 总结与展望

随着计算机科学技术的飞速发展以及人工智能时代的到来，图像作为一种最直观有效的信息传达方式发挥着越来越重要的作用。图像分割技术作为图像分析与理解的必要前提，受到国内外研究学者持续和广泛的研究。其中，基于水平集的图像分割算法凭借其算法优势成为近年来图像分割领域的重要研究方向并得到了迅速发展。本文针对现有水平集图像分割算法存在的问题，在此基础上进行了深入研究与改进，并通过一系列科学严谨的实验来证明本文改进算法的有效性。本章将对此次的研究成果进行总结并对水平集图像分割算法未来的研究方向进行展望。

5.1 工作总结

本文所做的创新性工作总结如下：

(1)针对现有局部模型在分割灰度不均匀图像时容易陷入局部极小值造成分割失败的现象，提出了一种改进的能够有效解决局部极小值问题的模型 VLIF。该模型结合最大类间方差思想，在 LIF 模型的基础上增加类间方差能量项，通过最大化演化曲线上所有点的邻域内目标和背景的差异来剔除使演化曲线陷入局部极小值的伪边界点，驱使演化曲线停最终留在正确的目标边界。实验结果表明改进的模型可以有效地解决局部模型因陷入局部极小值而导致的误分割问题，提高对灰度不均匀以及复杂图像的分割准确度。

(2)结合图像熵的思想提出了一种权重自适应的融合图像全局信息与局部信息的模型。利用图像局部熵建立了精确可靠的衡量图像灰度信息的指标，通过实时获取图像分割过程中的灰度分布情况自适应的指导模型中不同功能能量项配比，实现全自动化分割。相比传统基于反复试验的固定参数线性调整模式，本文选择了一种更加量化和合理的方式实现了全局项与局部项的动态非线性调整，实现了对多种类型图像的快速准确分割。最后通过一系列实验表明本文模型对于不同类型的灰度不均匀和噪声图像，能够完成快速准确的分割，且稳定性较高，对初始轮廓的位置也不敏感。

5.2 工作展望

随着各行各业对计算机视觉处理需求的急剧增加，以及人工智能的发展对图像分割算法带来的新挑战，如何不断提高图像分割算法的性能来适应难度升级的应用需求成为国内外科研人员孜孜不倦进行研究改进的动力来源。本文在现有水平集图像分割算法基

础上针对现有模型容易陷入局部极小值造成分割失败以及权重参数自适应两个难点进行了改进，有效提高了模型对多种灰度不均匀图像的分割性能，但是仍然有很大的空间值得我们去改进，现将本文下一步的研究方向总结如下：

（1）水平集图像分割算法具有很好的信息包容性，下一步将结合机器学习算法，在水平集图像分割模型中融入大量图像训练样本的先验信息，使其能够应用到更复杂的实践场景中。此外会分析其他多种算法，寻找各算法进行融合的切入点，实现对现有图像分割方法的完善和扩展，生成作用范围更广更贴近实际应用的多信息共融算法。

（2）为了充分的整合图像的多种特征，考虑将图像的颜色信息以及结构特征如形状，纹理特征等与水平集图像分割算法相结合，进一步提高图像分割算法的准确性及丰富场景中的适用性。

（3）随着成像设备的不断升级，需要处理的图像尺寸也急剧增大，加之实际应用中对图像处理速度的极致追求，目前所提出的分割算法在很多时候并不能满足实际应用时的快速分割需求。因此下一步将改进模型的数值求解方案来减少分割所需的运算时间，实现实际应用中大尺度图像的快速实时分割。

（4）随着计算机视觉在三维场景中的普及应用，如何处理三维立体图形也是图像分割面临的挑战，因此将水平集图像分割方法应用到三维立体图像是我们下一步研究的方向之一。

参考文献

- [1] 史娜. 基于变分水平集方法的图像分割和目标轮廓跟踪研究[D]. 中北大学, 2014.
- [2] 方江雄. 基于变分水平集的图像分割方法研究[D]. 上海交通大学, 2012.
- [3] 吴永飞. 图像分割的变分模型及数值实现[D]. 重庆大学, 2016.
- [4] 章毓晋. 图像分割[M].北京:科学出版社, 2001, pp: 75-83.
- [5] 李军. 基于活动轮廓模型的图像分割方法研究[D].西南交通大学,2017.
- [6] 江晓亮. 基于模糊聚类及活动轮廓模型的图像分割技术研究[D].西南交通大学,2016.
- [7] 孙研. 基于智能优化算法的多阈值图像分割技术及其并行加速[D].南京理工大学,2014.
- [8] 许晓丽. 基于聚类分析的图像分割算法研究[D]. 哈尔滨工程大学, 2012.
- [9] 李传龙. 基于水平集和模糊聚类方法的图像分割技术研究[D]. 大连海事大学, 2012.
- [10] Xie X, Wang T. A projection twin SVM-based active contour model for image segmentation[C]// International Conference on Mechatronics and Machine Vision in Practice. IEEE, 2017:1-4.
- [11] Niu S, Chen Q, Sisternes L D, et al. Robust noise region-based active contour model via local similarity factor for image segmentation[J]. Pattern Recognition, 2016, 61:104-119.
- [12] 庞双双. 基于水平集的非匀质医学图像分割算法研究[D]. 山东师范大学, 2016.
- [13] 杨红喆. 水平集理论及其在医学图像分割中的应用[D]. 北京理工大学, 2014.
- [14] Shyu K K, Tran T T, Pham V T, et al. Fuzzy distribution fitting energy-based active contours for image segmentation[J]. Nonlinear Dynamics, 2012, 69(1-2):295-312.
- [15] Muda A F, Saad N M, Waeleh N, et al. Integration of Fuzzy C-Means with Correlation Template and Active Contour for Brain Lesion Segmentation in Diffusion-Weighted MRI[C]// International Conference on Artificial Intelligence, Modelling and Simulation. IEEE, 2016:268-273.
- [16] 肖小龙. 基于区域的图像分割及视觉显著性检测算法研究[D]. 华东理工大学, 2014.
- [17] Yang X, Gao X, Tao D, et al. An Efficient MRF Embedded Level Set Method for Image Segmentation[J]. IEEE Transactions on Image Processing A Publication of the IEEE Signal Processing Society, 2015, 24(1):9.
- [18] 闵海. 基于区域型水平集方法的图像分割算法研究[D]. 中国科学技术大学, 2014.
- [19] Osher S, Fedkiw R. Level Set Methods and Dynamic Implicit Surfaces [M].New York: Springer, 2003.

- [20] Caselles V, Catte F, Coll T, et al. A Geometric Model for Active Contours[J]. *Numeric Mathematik*, 1993, 66(1):1-31.
- [21] Liu C, Liu W, Xing W. An improved edge-based level set method combining local regional fitting information for noisy image segmentation[J]. *Signal Processing*, 2017, 130:12-21.
- [22] 杨松, 罗培, 罗浩元, 杨欣. 基于改进的 GAC 模型图像分割算法 [J]. *光学技术*, 2016, 42(02):185-192.
- [23] 高士瑞, 侯榆青, 张海波, 程兴宏. 引入新的停止函数的 GAC 模型医学图像序列分割[J]. *计算机应用研究*, 2012, 29(11):4385-4389.
- [24] Liu W, Shang Y, Yang X. Active contour model driven by local histogram fitting energy[J]. *Pattern Recognition Letters*, 2013, 34(6):655-662.
- [25] Wang L, Chang Y, Wang H, et al. An active contour model based on local fitted images for image segmentation[J]. *Information Sciences*, 2017, s 418–419:61-73.
- [26] Zhang R. A Hybrid Active Contour Model with Local Gaussian Distribution Fitting Energy for Image Segmentation[J]. *Journal of Information & Computational Science*, 2015, 12(17):6515-6523.
- [27] Mumford D, Shah J. Optimal approximations by piecewise smooth functions and associated variational problems[J]. *Communications on Pure & Applied Mathematics*, 1989, 42(5):577–685.
- [28] Chan T, Vese L. Active contours without edges[J]. *IEEE Transactions on Image Processing*, 2001, 10(2): 266-277.
- [29] Li C, Kao C Y, Gore J C, et al. Implicit Active Contours Driven by Local Binary Fitting Energy[C]// *IEEE Conference on Computer Vision & Pattern Recognition*, 2007:1-7.
- [30] Zhang K P, Song H H, Zhang L. Active contours driven by local image fitting energy [J]. *Pattern Recognition*, 2010, 43(4):1199-1206.
- [31] Wang L, He L, Mishra A, et al. Active contours driven by local Gaussian distribution fitting energy[J]. *Signal Processing*, 2009, 89(12):2435-2447.
- [32] Wang Y, Xiang S, Pan C, et al. Level set evolution with locally linear classification for image segmentation[J]. *Pattern Recognition*, 2013, 46(6):1734-1746.
- [33] Gupta D, Anand R S, Tyagi B. A hybrid segmentation method based on Gaussian kernel fuzzy clustering and region based active contour model for ultrasound medical images[J]. *Biomedical Signal Processing & Control*, 2015, 16:98-112.

- [34] 王大凯, 侯榆青, 彭进业. 图像处理的偏微分方程方法[M]. 北京: 科学出版社, 2008
- [35] 老大中. 变分法基础[M]. 北京:国防工业出版社, 2010. 37-173.
- [36] 方玲玲. 图像分割的活动轮廓模型研究[D]. 苏州大学, 2013.
- [37] 章润如. 基于局部区域活动轮廓模型的图像分割方法研究[D]. 中国科学技术大学, 2016.
- [38] M. Kass, A. Witkin, D. Terzopoulos. Snakes: active contour models[J]. International Journal of Computer Vision, 1988, 1(4): 321-331.
- [39] Wang Xiaofeng, Min Hai, Zhang Yigang. Multi-scale local region based level set method for image segmentation in the presence of intensity inhomogeneity[J]. Neurocomputing, 2015, 151(3):1086-1098.
- [40] Zheng Qiang, Dong Enqing, Cao Zhulou, et al. Active contour model driven by linear speed function for local segmentation with robust initialization and applications in MR brain images[J]. Signal Processing, 2014, 97(7):117-133.
- [41] Liu Shigang, Peng Yali. A local region-based Chan–Vese model for image segmentation[J]. Pattern Recognition, 2012, 45(7):2769-2779.
- [42] Yuan Jianjun, Wang Jianjun, Liu Lipai. Active contours driven by local intensity and local gradient fitting energies[J]. International Journal of Pattern Recognition & Artificial Intelligence, 2014, 28(3):1455006.
- [43] 黄永刚, 梁新刚. 基于区域相似度的局部拟合活动轮廓模型[J]. 计算机工程, 2016, 42(11):249-254.
- [44] 林静, 王美清. 局部窗口动态选择的 RSF 模型[J]. 福州大学学报(自然科学版), 2016, 44(03):413-418.
- [45] Ji Z, Xia Y, Sun Q, et al. Active contours driven by local likelihood image fitting energy for image segmentation[J]. Information Sciences An International Journal, 2015, 301(C):285-304.
- [46] Li C M, Kao C Y, Gore JC, et al. Minimization of region-scalable fitting energy for image segmentation[J]. IEEE Transaction on Image Processing 2008, 17(10):1940–1949.
- [47] Ostu N. A threshold selection method from gray-level histogram[J]. IEEE Transactions on Systems, Man and Cybernetics, 1979, 9(1): 62-66.
- [48] 丁晓峰, 何凯霖. 基于最大类间方差的改进图像分割算法[J]. 计算机工程与设计, 2015(10):2765-2768.
- [49] 原野. 偏微分方程图像分割模型研究[D]. 重庆大学, 2012.

- [50] 廖祥云, 袁志勇, 郑奇,等. 引入局部全局信息的区域自适应局域化快速活动轮廓模型[J]. 计算机学报, 2016, 39(7):1464-1476.
- [51] 刘伟,黄洁,甄勇等. 利用局部离散度活动轮廓模型的强度非均匀图像分割[J]. 信号处理, 2016, 32(3):335-340.
- [52] Wang X F, Huang D S, Xu H. An efficient local Chan–Vese model for image segmentation[J]. Pattern Recognition, 2010, 43(3):603-618.
- [53] Wang L, Li C M, Sun Q, et al. Active contours driven by local and global intensity fitting energy with application to brain MR image segmentation [J]. Computerized Medical Imaging and Graphics, 2009, 33(7), 520-531.
- [54] Zhao Y Q, Wang X F, Frank Y. Shih, et al. A level-set method based on global and local regions for image segmentation[J]. Pattern Recognition and Artificial Intelligence. 2012, 26(1):1-14.
- [55] 戚世乐, 王美清. 结合全局和局部信息的“两阶段”活动轮廓模型[J]. 中国图象图形学报, 2014, 19(3):421-427.
- [56] Shannon C E. A mathematical theory of communication[J]. Bell System Technical Journal, 1948, 27(4):379-423.
- [57] He Chuanjiang, Wang Yan, Chen Qiang. Active contours driven by weighted region-scalable fitting energy based on local entropy[J]. Signal Processing, 2012, 92(2):587-600.
- [58] Chen Y F, Zhao W, Wang Z. Level set segmentation algorithm based on image entropy and simulated annealing[C]// Proceedings of International Conference on Bioinformatics and Biomedical Engineering. Wuhan:IEEE Computer Society, 2007:999-1003.
- [59] Song Yu, Wu Yiquan, Dai Yimian. A new active contour remote sensing river image segmentation algorithm inspired from the cross entropy[J]. Digital Signal Processing, 2016, 48(C):322-332.
- [60] Han B, Wu Y. A novel active contour model based on modified symmetric cross entropy for remote sensing river image segmentation[J]. Pattern Recognition, 2017, 67:396-409.
- [61] 朱永杰, 邱天爽. 基于改进 LGDF 模型的超声图像自动分割方法[J]. 大连理工大学学报, 2016, 56(1):28-34.
- [62] 张芹. 基于改进 CV 模型的图像分割技术研究[D]. 山东师范大学, 2013.
- [63] 王斌, 李洁, 高新波. 一种基于边缘与区域信息的先验水平集图像分割方法[J]. 计算机学报, 2012, 35(5):1067-1072.

- [64] 薛维琴, 周志勇, 张涛,等. 灰度不均的弱边缘血管影像的水平集分割方法[J]. 软件学报, 2012, 23(9):2489-2499.
- [65] 吴杰, 朱家明, 张辉. 灰度不均的弱边界血管图像分割方法[J]. 计算机应用, 2016, 36(a01):154-156.
- [66] ZHAO Y, Rada L, Chen K, et al. Automated Vessel Segmentation Using Infinite Perimeter Active Contour Model with Hybrid Region Information with Application to Retinal Images[J]. IEEE Transactions on Medical Imaging, 2015, 34(9):1797-1807.
- [67] 郝智慧, 郭满才, 宋杨杨. 结合全局与局部信息活动轮廓的非同质图像分割[J]. 中国图象图形学报, 2016, 21(7):886-892.
- [68] 罗德芳. Chan-Vese 活动轮廓模型的研究[D]. 重庆大学, 2011.
- [69] 王晓峰. 水平集方法及其在图像分割中的应用研究[D]. 中国科学技术大学, 2009.
- [70] 刘乐. 变分法图像分割算法研究[D]. 长春工业大学, 2016.
- [71] 陈雷. 基于活动轮廓模型的图像分割算法研究[D]. 山东大学, 2013.

致谢

伴随着论文的最后，三年的研究生时光也迎来了告别的时刻，那些徜徉在文献海洋里的时光，那些调试实验至深夜的时光，转眼间就将要成为回忆，我相信这段纯碎的，充实的科研生涯将成为我一生最值得追忆的时光。

衷心地感谢我的导师，邓红霞教授。邓老师是一个待人亲切和善，品德高尚的老师，因此深受同学们的喜爱。能够成为邓老师的学生，让我深感荣幸。此外，邓老师深厚的学术积累，严谨的治学态度，开拓创新的科研理念，诲人不倦的敬业精神以及孜孜不倦的人生追求也为我树立了一辈子学习的典范，在为人处世中也以开放包容的胸怀，积极乐观的生活态度，亲切和蔼的人格魅力深深地感染着我。

感谢李钢老师，三年来对我的悉心教导和严格的要求。同时李老师在我刚读研时候的教诲我也时刻铭记于心，老师说“研究生期间的学习，不仅仅要掌握和钻研专业的学术知识，更重要的是掌握一门科学的解决问题的方法，这将成为你以后工作和生活中最宝贵的财富”。我相信三年来对自身的严格要求和时刻的反省与感悟，让我获得了这样的财富，并将在未来的日子里带着这份财富一路前行。

感谢课题组老师李海芳教授，三年来耐心听取我们的每一次阶段汇报，并以她多年积累的深厚学术经验和敏锐的洞察力，为我们每一个环节把关，及时提出相应的修改方案，从而保证了课题的顺利进行。

感谢我的母校太原理工大学，感谢计算机科学与技术学院，为我们提供了一流的教学资源和科研环境。在这里我相继完成了本科和研究生时期的学习，也留下了七年美好的回忆。这是一个承载着我的青春和梦想的地方，在这里我收获了宝贵的知识，收获了一生的挚友，也找到了人生的方向。

感谢我的同门，实验室同学以及所有帮助过我的朋友，包括那些在科研互助群里未曾谋面却一直陪伴我整个学术生涯的战友，我们一起并肩学习，交流学术，共享资源，分享攻克一个个难题时的喜悦也互相鼓励在遇到科研瓶颈时不灰心丧气。

感谢我的家人，给予我坚定的支持和默默无私的爱护。他们用最大的努力为我提供最好的生活环境和精神支持，使我全身心的投入学业

感谢这段经历，对我的人生产生了深远的意义。我将永远铭记这段美好的时光，带着这份光辉灿烂的回忆在未来的人生道路上砥砺前行。

攻读学位期间发表的学术论文目录

发表论文

[1]赵怡,邓红霞,张玲,李钢.基于最大类间方差的权重自适应活动轮廓模型[J].计算机工程与设计,2018,39(02):486-491.

[2]李钢,李海芳,赵怡,邓红霞.修正局部极小值的局部灰度差异分割模型[J].计算机工程与应用.(已录用)

科研情况

国家自然科学基金资助项目（61373101,61472270,61402318）

山西省自然科学(青年科技研究)基金资助项目（2014021022-5）